Penerapan Transformasi Box-Cox dan Regresi *Stepwise* dalam Pemodelan Pertumbuhan Ekonomi di Pulau Jawa Tahun 2023

Alden Nabil Wibowo Effendy[1‡], Muhammad Fauzan Nur Rasendriya[1], Fatih Avicenna Hizir[1], Muhammad Bagas Ramadhan[1], I Made Sumertajaya[1], Farik Firsteadi Haristiyanto[1]

[1]Department of Statistics, IPB University, Indonesia
[‡]Corresponding author: aldennabil31effendy@apps.ipb.ac.id

Abstrak

Pertumbuhan ekonomi daerah merupakan indikator penting dalam menilai kesejahteraan dan ketimpangan pembangunan antarwilayah. Pulau Jawa sebagai pusat kegiatan ekonomi nasional, menyumbang hampir 60% dari PDRB nasional. Penelitian ini bertujuan untuk menganalisis faktor-faktor yang memengaruhi pertumbuhan ekonomi daerah di Pulau Jawa pada 2023 dengan menggunakan pendekatan regresi berganda, transformasi Box-Cox, dan seleksi *stepwise*. Data sekunder diperoleh dari Badan Pusat Statistik (BPS), mencakup variabel indeks pembangunan manusia, rataan lama sekolah, jumlah wisatawan domestik, tingkat kemiskinan, luas lahan padi, jumlah pekerja, jumlah pengangguran, jumlah angkatan kerja. Hasil analisis menunjukkan bahwa transformasi *Box-Cox* mampu mengatasi pelanggaran asumsi regresi klasik serta meningkatkan kualitas model. Setelah dilakukan seleksi variabel dan penghapusan observasi pencilan, diperoleh model akhir dengan *adjusted* R^2 sebesar 80,7% dan rata-rata selisih absolut (MAE) 0,7439. Lima variabel terpilih terbukti berpengaruh signifikan terhadap PDRB dan secara bersama-sama menjelaskan variasi ekonomi antar daerah di Pulau Jawa.

Kata kunci: PDRB, transformasi Box-Cox, regresi berganda, *stepwise*, pertumbuhan ekonomi

1. Pendahuluan

Pertumbuhan ekonomi merupakan indikator utama pembangunan suatu wilayah. Kekuatan ekonomi daerah dapat dicerminkan melalui produk domestik regional bruto (PDRB), yang mencerminkan total nilai barang dan jasa yang dihasilkan dalam suatu wilayah selama periode tertentu (Putra dan Pratama 2022). Pulau Jawa menyumbang hampir 60% dari PDRB nasional pada tahun 2023, menunjukkan dominasi ekonomi yang signifikan dibandingkan wilayah lain di Indonesia, meskipun kontribusi ini tidak merata di semua provinsi di pulau tersebut (Wijayanti dan Mufarrah 2024). Ketimpangan antarprovinsi di Pulau Jawa terlihat dari disparitas PDRB per kapita dan distribusi sumber daya ekonomi, yang menyebabkan perbedaan tingkat kesejahteraan

antarwilayah (Violin dan Lutfi 2022). PDRB dihitung melalui pengeluaran konsumsi rumah tangga, investasi sektor publik dan swasta, serta ekspor netto yang mencakup selisih antara ekspor dan impor wilayah (BPS 2024). Namun, konsumsi domestik lebih berpengaruh dibandingkan ekspor netto dalam konteks regional seperti Pulau Jawa, karena permintaan dalam negeri, terutama dari sektor rumah tangga dan industri, menjadi pendorong utama untuk pertumbuhan ekonomi di wilayah Pulau Jawa (Judijanto dan Azizs 2024).

Indeks Pertumbuhan Masyarakat (IPM) mencerminkan kualitas sumber daya manusia dan berdampak pada pertumbuhan ekonomi (Ridho 2021). Kondisi pendidikan penduduk suatu wilayah yang tercermin dari rata-rata lama sekolah terbukti meningkatkan produktivitas tenaga kerja (Huda dan Indahsari 2021). Sedangkan sektor pariwisata mendorong pertumbuhan ekonomi melalui penciptaan lapangan kerja dan peningkatan konsumsi (Setiawan *et al*. 2022). Sebaliknya, pengangguran dan kemiskinan menekan pertumbuhan ekonomi secara signifikan (Azzahra *et al*. 2024; Trisnawati dan Prasetyanto 2022). Selain itu, luas lahan dan tenaga kerja berpengaruh terhadap sektor pertanian (Sari dan Juliansyah 2024). Namun, efisiensi industri tidak selalu meningkatkan penyerapan tenaga kerja (Nababan dan Purba 2023). Pertumbuhan angkatan kerja, khususnya usia produktif, secara positif berdampak terhadap pertumbuhan ekonomi dalam jangka panjang karena kontribusi dominan dari tenaga kerja terampil (Ghassan et al. 2018).

Oleh karena itu, penting untuk mengidentifikasi faktor-faktor yang memengaruhi pertumbuhan ekonomi daerah di Pulau Jawa serta menentukan model statistik yang sesuai untuk menjelaskannya. Berdasarkan rumusan masalah tersebut, penelitian ini bertujuan untuk menganalisis peubah-peubah yang memengaruhi pertumbuhan ekonomi di Pulau Jawa pada tahun 2023 melalui penerapan transformasi Box-Cox dan regresi *stepwise* agar memperoleh model regresi terbaik. Hasil penelitian ini diharapkan dapat menjadi dasar bagi perumusan kebijakan ekonomi yang lebih akurat dan efektif.

2. Metodologi

2.1 Bahan dan Data

Data yang digunakan dalam penelitian ini merupakan data sekunder yang bersumber dari publikasi resmi Badan Pusat Statistik (BPS) 2023. Data mencakup enam provinsi yang berada di Pulau Jawa, yaitu DKI Jakarta, Banten, Jawa Barat, Jawa Tengah, DI Yogyakarta, dan Jawa Timur.

Peubah respon dalam penelitian ini adalah Produk Domestik Regional Bruto (PDRB). Adapun peubah penjelas yang digunakan dalam penelitian ini dipilih berdasarkan hasil studi literatur sebelumnya, yang meliputi:

Tabel 1 Peubah yang digunakan dalam penelitian

Peubah	Nama Peubah	Satuan	Sumber	Referensi

Y	Produk Domestik Regional Bruto	Juta Rupiah	BPS (2023)	(Putra dan Pratama 2022)
X1	Indeks Pembangunan Manusia	Skor (0-100)	BPS (2023)	(Ridho 2021)
X2	Rataan Lama Sekolah	Tahun	BPS (2023)	(Huda dan Indahsari 2021)
X3	Jumlah Wisatawan Nasional	Jiwa	BPS (2023)	(Setiawan et al. 2022)
X4	Tingkat Kemiskinan	Persen (%)	BPS (2023)	(Trisnawati dan Prasetyanto 2022)
X5	Luas Lahan Padi	Hektar	BPS (2023)	(Sari dan Juliansyah 2024)
X6	Jumlah Pekerja	Jiwa	BPS (2023)	(Nababan dan Purba 2023)
X7	Jumlah Pengangguran	Jiwa	BPS (2023)	(Azzahra et al. 2024)
X8	Jumlah Angkatan Kerja	Jiwa	BPS (2023)	(Ghassan et al. 2018)

2.2 Metode Penelitian

Proses analisis data dilakukan menggunakan perangkat lunak RStudio. Prosedur analisis yang dilakukan adalah sebagai berikut.

1. Melakukan eksplorasi data awal pada peubah respon (Produk Domestik Regional Bruto). Visualisasi sebaran data dilakukan menggunakan histogram dan Boxplot. Selain itu, dilakukan uji normalitas menggunakan uji Shapiro-Wilk, untuk mendapatkan gambaran awal mengenai pemenuhan asumsi normalitas $H_0 : Y \sim Normal$.
2. Membuat dan menganalisis matriks korelasi antar peubah. Untuk memahami hubungan linear antar peubah yang diteliti, dihitung koefisien korelasi Pearson (r) antar setiap pasang variabel. Matriks korelasi, yang berisi nilai $r_{Xi,Xj}$, $dan\ r_{Y,Xi}$, dianalisis untuk mengetahui arah dan kekuatan hubungan linear, serta memberikan deteksi dini terhadap potensi masalah multikolinearitas.
3. Melakukan pendugaan model regr esi linear berganda awal. Model regresi linear berganda awal dibentuk untuk menjelaskan hubungan antara peubah dependen (Y) dengan seluruh peubah penjelas. Persamaan modelnya adalah sebagai berikut.

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \beta_7 X_7 + \beta_8 X_8 + \varepsilon.$$

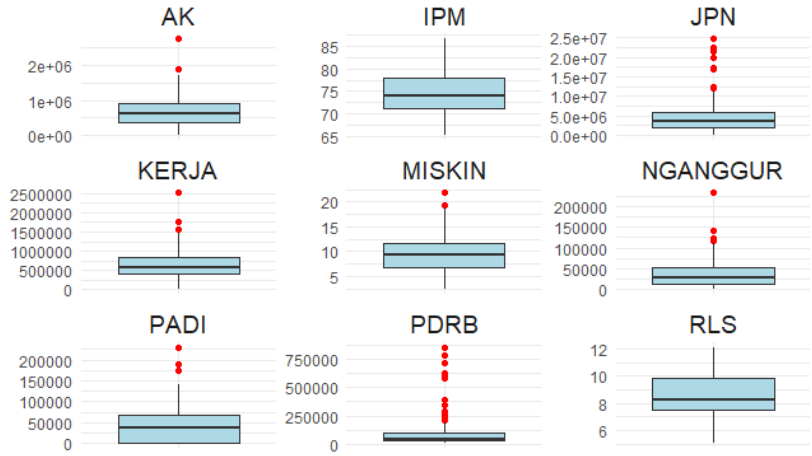
Parameter model diestimasi menggunakan metode Ordinary Least Squares (OLS).

4. Melakukan pengujian asumsi klasik terhadap model regresi awal untuk memastikan validitas model awal.
   a. Uji Normalitas Galat ($H0 : \varepsilon \sim Normal$) menggunakan Shapiro-Wilk test dan analisis visual Q-Q Plot terhadap residual (ε_i).
   b. Uji Homoskedastisitas Ragam Galat ($H0 : Var(\varepsilon_i) = \sigma^2 \ untuk \ semua \ i$) menggunakan Breusch-Pagan test yang umumnya menghasilkan statistik uji $\chi 2$ atau F.
   c. Uji Autokorelasi Galat ($H_0 : \rho = 0$) menggunakan statistik Durbin-Watson ($DW = \frac{\sum(e_t - e_{t-1})}{\sum e_t^2}$.
   d. Uji Multikolinearitas menggunakan *Variance Inflation Factor* ($VIF_j = \frac{1}{1-R_j^2}$), di mana R_j^2 adalah R^2 dari regresi X_j terhadap peubah penjelas lainnya.
5. Melakukan evaluasi kelayakan model dan signifikansi koefisien regresi pada model awal. Kelayakan model awal dievaluasi menggunakan:
   a. Uji Signifikansi Simultan (Uji F), dengan hipotesis nol $H_0 : \beta_1 = \beta_2 = \cdots = \beta_8 = 0$. Statistik uji $F = \frac{MSR}{MSE}$.
   b. Uji Signifikansi Parsial (Uji t) untuk setiap koefisien, dengan hipotesis nol $H_0 : \beta_j = 0$. Statistik uji $t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$.
   c. Koefisien Determinasi yang Disesuaikan (R_{adj}^2), (R_{adj}^2)= $1 - [(1 - R^2)(n - 1)/(n - k - 1)]$, dimana k adalah jumlah peubah penjelas.
6. Melakukan penanganan terhadap pelanggaran asumsi klasik yang teridentifikasi. Untuk mengatasi pelanggaran asumsi, dilakukan beberapa pendekatan:
   a. Transformasi Logaritma: $Y_{log} = \ln(Y)$.
   b. Transformasi Box-Cox: $Y_{BoxCox}^{(\lambda)} = \frac{(Y^\lambda - 1)}{\lambda}$ untuk $\lambda \neq 0$, dan $Y_{BoxCox}^{(0)} = ln(Y)$ untuk $\lambda = 0$. Nilai λ optimal dicari dengan memaksimalkan fungsi loglikelihood $L(\lambda)$.
   c. Model Regresi Robust: Menggunakan estimasi M atau metode lain yang diimplementasikan dalam fungsi seperti rlm().
7. Melakukan pemilihan model terbaik sementara dan melakukan analisis diagnostik untuk mengidentifikasi observasi berpengaruh. Ini melibatkan pemeriksaan nilai leverage (h_{ii}), residual terstudentisasi (r_i), Cook's Distance (D_i), dan $DFFITS_i$. Observasi yang melebihi batas kritis tertentu pada statistik ini dipertimbangkan untuk ditangani atau dikeluarkan.
8. Melakukan pemilihan model akhir menggunakan metode regresi stepwise dengan pendekatan *both direction*. Kriteria yang digunakan untuk seleksi variabel adalah Akaike Information Criterion (AIC), yang dihitung sebagai $AIC = 2p - 2\ln(\hat{L})$ atau $AIC = n \ln(\frac{RSS}{n}) + 2p$. Tujuannya adalah meminimalkan AIC.
9. Melakukan pengujian ulang asumsi klasik seperti pada poin 4 dan evaluasi kelayakan seperti pada poin 5 pada model akhir.
10. Melakukan interpretasi terhadap koefisien regresi dari model akhir yang terpilih.

3. Hasil dan Pembahasan

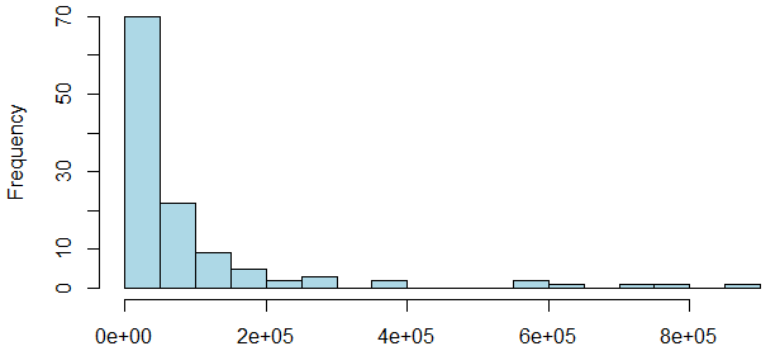
3.1 Eksplorasi Data

Sebelum membangun model regresi, eksplorasi data diperlukan untuk memahami karakteristik distribusi dan hubungan antarvariabel. Tahapan ini penting untuk memastikan bahwa data memenuhi asumsi dasar regresi serta untuk menghindari pemodelan yang keliru akibat pola data yang tidak terdeteksi sebelumnya. Sebaran dari seluruh peubah yang digunakan disajikan dalam bentuk *boxplot* sebagai berikut.



Gambar 1 *Boxplot* seluruh variabel

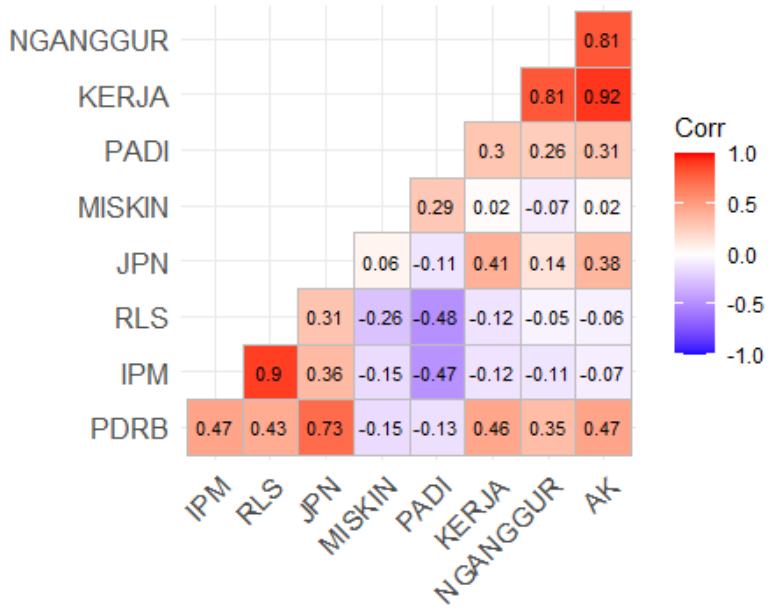
Terlihat beberapa variabel memiliki sebaran yang tidak berbentuk normal (menyerupai lonceng), terlebih untuk peubah respon (PDRB). Hal ini mengindikasikan adanya nilai-nilai ekstrem yang perlu ditangani dalam analisis lebih lanjut untuk memastikan keabsahan model regresi. Peubah respon yang tidak menyebar normal berpotensi melanggar asumsi normalitas residual yang dibutuhkan oleh regresi.



Gambar 2: Histogram variabel PDRB

Distribusi PDRB yang miring ke kanan mendukung perlunya transformasi logaritma untuk memperbaiki asumsi normalitas. Uji normalitas untuk peubah respon menghasilkan nilai p sebesar $2{,}2 \times 10^{-16}$ mengartikan peubah respon tidak menyebar normal.

Selanjutnya perlu melihat korelasi untuk mengetahui kekuatan dan arah hubungan antarvariabel serta mendeteksi indikasi multikolinearitas.



Gambar 3: Matriks korelasi

Matriks korelasi menunjukkan hubungan positif kuat antara PDRB dan Jumlah isatawan. Adapun hubungan PDRB dengan angkatan kerja, Indeks Pembangunan Manusia, Rata Lama Sekolah, dan Jumlah Pengangguran yang menunjukan korelasi positif cukup. Sementara itu ada hubungan negatif sangat lemah antara PDRB dengan Tingkat Kemiskinan dan Luas Lahan Padi. Korelasi sangat kuat berentan dari 0,75 - 0,99; korelasi kuat berentan dari 0,5 - 0,7; dan korelasi cukup berentan dari 0,25 - 0,5; Di bawah itu mengartikan bahwa hubungan sangat lemah atau tidak ada korelasi.

3.2 Pemodelan Awal dan Pengujian Asumsi

1. Model Awal

   Pemodelan awal dilakukan dengan menyertakan seluruh variabel independen. Secara simultan, didapatkan nilai p sebesar 2.2×10^{-12} yang menunjukkan bahwa model regresi sudah layak untuk dilakukan analisis regresi berganda. Model awal ditunjukkan oleh persamaan (2).

$$PDRB = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \beta_7 X_7 + \beta_1 X_1 + \varepsilon$$

   Berdasarkan uji parsial, dari 8 peubah penjelas yang diteliti, hanya terdapat 4 peubah signifikan, yaitu X1, X3, X4, dan X7 dengan nilai adjusted R2 sebesar 66,22%.

2. Uji Asumsi Klasik

   Uji asumsi dalam model regresi penting dilakukan untuk memastikan validitas dan keandalan hasil estimasi. Asumsi perlu diuji agar model yang dibangun tidak menghasilkan kesimpulan yang menyesatkan atau berbias. Tanpa pengujian ini, interpretasi koefisien regresi dan hasil uji signifikan statistik dapat menjadi tidak akurat. Hasil uji asumsi model awal disajikan sebagai berikut.

Tabel 2 Ringkasan uji asumsi model awal

Uji Asumsi	Metode Uji	Nilai Statistik Uji	Batas kritis/Aturan	Kesimpulan (taraf=5%)
Normalitas Galat	Uji Shapiro-Wilk	W = 0.846	Nilai p 0.05	Tidak Normal
Homoskedastisitas	Uji Breusch-Pagan	BP = 16.358	Nilai p 0.05	Heteroskedastisitas
Autokorelasi Galat	Uji Durbin Watson	DW = 1.714	Nilai p 0.05 atau DW mendekati 2	Autokorelasi Positif
Multikolinearitas	VIF	X1: 5.97, X2: 6.25, X3: 1.88, X4: 1.23, X5: 1.56, X6: 8.90, X7: 4.00, X8: 7.51	VIF < 10 (umum) VIF > 5 (indikasi kuat)	Ada Indikasi Multikolinearitas pada X6, X8, X2, X1

Model regresi awal gagal memenuhi asumsi normalitas dan homoskedastisitas, dan autokorelasi. Selain itu, beberapa variabel juga mengindikasikan adanya multikolinearitas. Hal ini dapat disebabkan oleh ketidaknormalan sebaran dan pencilan pada variabel, skala data yang tidak seimbang, dan struktur spasial data di Pulau Jawa.

3.3 Transformasi Variabel Dependen dan Uji Asumsi Model Hasil Transformasi.

1. Model Log

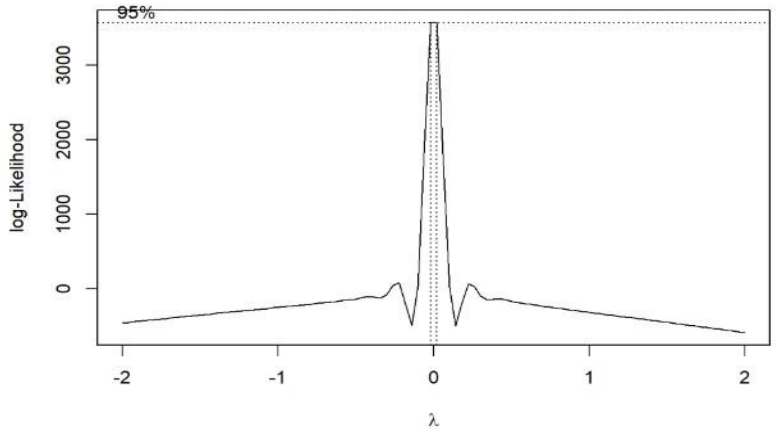
   Transformasi logaritma dilakukan terhadap variabel dependen PDRB untuk mengatasi distribusi yang tidak normal. Model regresi menggunakan variabel dependen yang telah di-logaritmakan:

$$PDRB_{Log} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \beta_7 X_7 + \beta_8 X_8 + \varepsilon$$

2. Uji Box-Cox

   Untuk mencari transformasi optimal yang dapat memperbaiki asumsi model awal, metode *box-cox* dapat digunakan. Metode ini melibatkan pencarian nilai lambda optimal yang mengoptimalkan log-*likelihood* dari model regresi. Nilai lambda optimal diperoleh melalui fungsi Box-Cox() dalam paket MASS pada bahasa

pemrograman R. Visualisasi lambda Box-Cox digunakan untuk menentukan nilai lambda optimal yang akan digunakan dalam transformasi Box-Cox.



Gambar 4 Visualisasi gambar *Box-Cox*

Gambar 4 menunjukkan plot log-*likelihood* terhadap nilai lambda. Dari plot tersebut, nilai lambda optimal adalah -0,0202. Nilai ini mendekati lambda untuk transformasi logaritma (0). Transformasi *Box-Cox* dilakukan terhadap variabel dependen $PDRB_{Box\text{-}Cox}$ menggunakan persamaan.

$$PDRB_{Box-\mathrm{Cox}} = \frac{PDRB^{\lambda}}{\lambda}$$

Setelah melakukan transformasi Box-Cox, model regresi baru dirumuskan sebagai berikut.

$$PDRB_{Box-Cox} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \beta_7 X_7 + \beta_8 X_8 + \varepsilon$$

3. Model Robust

Model Robust dengan fungsi rlm() dari paket MASS digunakan untuk mengatasi pengaruh pencilan yang kuat pada model awal. Model robust dirancang untuk lebih tahan terhadap observasi ekstrem dibandingkan model regresi linier biasa. Persamaan model robust adalah:

$$PDRB_{Robust} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6 + \beta_7 X_7 + \beta_8 X_8 + \varepsilon$$

Untuk melihat kelayakan dan kualitas model, diperoleh evaluasi model-model regresi dengan taraf kesalahan 5% sebagai berikut:

Tabel 3 hasil evaluasi model-model regresi

Model	Asumsi Normalitas galat	Asumsi homoskedastisitas	Asumsi autokorelasi	*Adjusted* R^2	*Residual standard error*

Model awal	Tidak terpenuhi	Tidak terpenuhi	Tidak terpenuh	0,66	90950
Model log	Tidak terpenuhi	Terpenuhi	Terpenuhi	0,69	0.5671
Model Box-Cox	Tidak terpenuhi	Terpenuhi	Terpenuhi	0,69	0.455
Model robust	Tidak terpenuhi	Tidak terpenuhi	Tidak terpenuhi	0,66	36390

Dari ketiga Transformasi, Model Box-Cox adalah yang terbaik walaupun galatnya belum berdistribusi normal. Oleh karena itu, langkah selanjutnya adalah melakukan deteksi pencilan dan penghapusan observasi berpengaruh untuk meningkatkan kualitas model.

3.4 Diagnostik Model

Untuk mengidentifikasi observasi berpengaruh (pencilan), kami menggunakan Jarak Cook's Distance , yang digunakan untuk mengukur pengaruh setiap observasi terhadap koefisien model secara keseluruhan. Observasi dengan nilai Cook's Distance yang lebih besar dari ambang batas berikut akan dianggap sebagai pencilan yang perlu diteliti lebih lanjut.

$$Treshold = \frac{4}{Jumlah\ Observasi}$$

Beberapa observasi memiliki nilai jarak Cook yang melebihi ambang batas, yaitu:

Tabel 4 Tabel Identifikasi Observasi Berpengaruh

ID Observasi	Provinsi	Kabupaten/Kota	Nilai jarak Cook
4	DKI Jakarta	Kota Jakarta Pusat	Sangat besar
7	Jawa Barat	Kab Bogor	Sangat besar
21	Jawa Barat	Kab Karawang	Cukup besar
34	Jawa Tengah	Kab Cilacap	Cukup besar
72	DI Yogyakarta	Kab Sleman	Sangat besar
101	Jawa Timur	Kab Pamekasan	Cukup besar
103	Jawa Timur	Kota Kediri	Cukup besar
114	Banten	Kab Tangerang	Sangat besar
117	Banten	Kota Cilegon	Sangat besar

Nilai jarak Cook yang sangat tinggi memiliki pengaruh signifikan terhadap koefisien model. Sedangkan nilai jarak Cook yang cukup besar perlu diperhatikan lebih lanjut.

Analisis lebih lanjut menggunakan nilai leverage mengidentifikasi observasi 3, 5, 7, 18, 51, 61, 71, 72, dan 110 sebagai observasi dengan leverage tinggi. Kemudian, pemeriksaan DFFITS menunjukkan bahwa observasi 4, 7, 21, 34, 72, 103, 114, dan

117 memiliki pengaruh yang sangat besar terhadap nilai prediksi model. Terakhir, analisis DFBETAS menunjukkan bahwa beberapa observasi memiliki pengaruh signifikan terhadap estimasi koefisien individu variabel penjelas, mengindikasikan bahwa pengaruh *pencilan* tidak hanya bersifat umum tetapi juga spesifik pada variabel tertentu.

Observasi dengan ID 4, 7, 72, 114, dan 117 secara konsisten menunjukkan nilainilai diagnostik yang tinggi (Cook's Distance, DFFITS, dan/atau DFBETAS). Hal ini menunjukkan bahwa mereka sangat berpengaruh terhadap estimasi koefisien model dan dapat mendistorsi hasil analisis. Oleh karena itu, penghapusan observasiobservasi ini (ID: 4, 7, 72, 114, 117) dilakukan untuk meningkatkan stabilitas model dan memperbaiki asumsi regresi.

Setelah menghapus observasi berpengaruh (ID: 4, 7, 72, 114, 117), model bersih menunjukkan peningkatan performa yang signifikan:

Tabel 5 Tabel ringkasan Uji asumsi model box-cox setelah menghilangkan pencilan

Asumsi Normalitas Galat	Asumsi Homoskedastisitas	Asumsi Autokorelasi	Adjusted R^2	Residual Standard Error
Terpenuhi	Terpenuhi	Tidak Tepenuhi	0,8046	0.385

Meskipun demikian, beberapa asumsi masih perlu diperbaiki lebih lanjut, terutama autokorelasi. Langkah selanjutnya adalah pemilihan model terbaik melalui pendekatan *stepwise* regression untuk memastikan variabel independen yang relevan dan signifikan terhadap PDRB.

3.5 Penentuan Model Terbaik dengan *Stepwise* Regression

Setelah model regresi awal dibentuk dan asumsi klasik diperbaiki melalui transformasi Box-Cox serta penghapusan pencilan, langkah selanjutnya adalah memilih model terbaik menggunakan metode *stepwise* regression . Tujuan dari tahapan ini adalah untuk menghasilkan model yang lebih sederhana namun tetap memiliki kemampuan prediksi yang tinggi dan interpretasi yang jelas.

Metode *stepwise* regression dilakukan dengan pendekatan both direction , yaitu kombinasi antara forward selection dan backward elimination , sehingga variabel yang dipilih merupakan subset optimal dari semua peubah independen berdasarkan kriteria AIC (Akaike Information Criterion). Proses pemilihan model menunjukkan bahwa beberapa peubah seperti X4, X2, dan X6 tidak memberikan kontribusi signifikan terhadap model dan oleh karena itu dihapus secara bertahap selama proses seleksi.

Tabel 6 Tabel ringkasan metode seleksi peubah *stepwise*.

Metode Seleksi	Peubah Bebas yang terlibat	AIC	R^2	Adjusted R^2	*Residual Standard Error*

Model Sebelum Seleksi	X1, X2, X3, X4, X5, X6, X7, dan X8	227.95	0.8188	0,8046	0.3445
Langkah 1	X1, X2, X3, X5, X6, X7, dan X8	229.91	0.8188	0.8065	0.3429
Langkah 2	X1, X3, X5, X6, X7, dan X8	231.12	0.8175	0.807	0.3425
Model Akhir *Stepwise*	X1, X3, X5, X7, dan X8	232.25	0.8161	0.8073	0.3422

Pemilihan model akhir ini merupakan hasil dari evaluasi berbagai metode seleksi model, termasuk *forward*, *backward*, dan *stepwise*. Metode *stepwise* secara khusus dipilih karena kemampuannya untuk mendapatkan model yang lebih *parsimonious* dengan memilih subset optimal dari semua peubah independen melalui proses kombinasi penambahan dan penghapusan variabel. Model akhir yang dihasilkan dari proses *stepwise* adalah:

$$PDRB_{Box\text{-}Cox} = \beta_0 + \beta_1 X_1 + \beta_3 X_3 + \beta_5 X_5 + \beta_7 X_7 + \beta_8 X_8 + \varepsilon$$

Hasil estimasi parameter menunjukkan bahwa kelima variabel tersebut memiliki pengaruh yang signifikan terhadap PDRB setelah transformasi Box-Cox dan penghapusan observasi berpengaruh.

3.6 Pengujian Asumsi Model Terbaik

Setelah didapatkan model terbaik, perlu dilakukan pengujian asumsi kembali. Hasil pengujian asumsi model terbaik disajikan pada tabel 3.

Tabel 7 Uji Asumsi Model Terbaik

Asumsi	Metode uji	Nilai p
Nilai harapan galat = 0	T-test	1
Kehomogenan ragam	Breusch Pagan test	0,6617
Kebebasan galat	Durbin Watson test	0,05452
Normalitas	Shapiro-Wilk test	0,7468

Pengujian terhadap empat asumsi tersebut menghasilkan nilai p yang lebih besar dari nilai alpha 0,05. Nilai p yang lebih besar dari nilai alpha artinya H0 tidak dapat ditolak. Artinya, model terbaik memenuhi asumsi Gauss-Markov dan normalitas.

3.7 Uji Kelayakan Model

Pengujian melalui F-Simultan menghasilkan nilai p sebesar $2{,}2 \times 10^{-16}$, nilai tersebut jauh lebih kecil dari titik kritis 0,05 sehingga peubah penjelas model terbaik secara bersama-sama berpengaruh terhadap peubah respon pada taraf 5%. Uji F-Simultan

yang menolak H_0 artinya minimal terdapat salah satu peubah penjelas yang berpengaruh terhadap respon. Uji F-Simultan hanya menguji model secara bersamaan sehingga perlu dilakukan kembali uji t-parsial untuk melihat signifikansi tiap peubah penjelas yang digunakan. Melalui uji t-parsial didapatkan data pada tabel 8.

Tabel 8 Uji t-parsial

Koefisien	Koefisien	Nilai p
Intersep	6,126	$< 2 \times 10^{-16}$
Indeks Pembangunan Manusia	$3,22 \times 10^{-2}$	$9,09 \times 10^{-5}$
Jumlah Wisatawan Nusantara	$8,52 \times 10^{-8}$	1,05 x 10-14
Luas Lahan Padi	$2,12 \times 10^{-6}$	0,021
Jumlah Pengangguran	$8,35 \times 10^{-6}$	3,10 x 10-6
Jumlah Angkatan Kerja	$5,29 \times 10^{-7}$	4,72 x 10-4

Nilai p pada Tabel 8 menunjukkan bahwa pada taraf nyata 5%, peubah penjelas yang signifikan terhadap peubah respon adalah Indeks Pembangunan Manusia, Jumlah Wisatawan Nusantara, Luas Lahan Padi, Jumlah Pengangguran, dan Jumlah Angkatan Kerja.

Model *stepwise* ini memiliki nilai R-Squared sebesar 0,816 dan adjusted RSquared sebesar 0,8073. Nilai ini dapat diinterpretasikan sebagai 80,73% dari keragaman peubah Y (PDRB) dapat dijelaskan oleh model regresi ini sedangkan 19,27% lainnya dapat dijelaskan oleh variabel lain di luar model.

Berdasarkan uji kelayakan, model sudah memenuhi kriteria sebagai model terbaik dengan ukuran kebaikan yang cukup tinggi sehingga dapat digunakan untuk memprediksi nilai respon.

3.8 Model Akhir: Interpretasi dan Evaluasi

Setelah melalui proses diagnostik model, ditemukan bahwa indeks pembangunan manusia (X1), jumlah Wisatawan nusantara (X3), luas lahan padi (X5), jumlah pengangguran (X7), dan jumlah angkatan kerja (X8) memiliki pengaruh signifikan terhadap PDRB.

Peubah Indeks Pembangunan Manusia (X1) menunjukkan tingkat pembangunan manusia yang mencakup indikator-indikator seperti pendidikan, kesehatan, dan standar hidup. Kita dapat menginterpretasikan bahwa jika indeks pembangunan manusia bertambah satu skor, maka kemungkinan nilai transformasi PDRB di Kota/Kabupaten di Pulau Jawa akan bertambah sebanyak 3,22 x 10-2 satuan. Ini sesuai dengan temuan Sari (2023) yang menyatakan bahwa semakin tinggi indeks pembangunan manusia maka produk domestik regional bruto pada daerah tersebut akan meningkat.

Peubah Jumlah Wisatawan Nusantara (X3) merujuk pada total jumlah individu dari dalam negeri yang melakukan perjalanan wisata ke berbagai destinasi di dalam wilayah tersebut. Interpretasi dari hasil ini adalah jika jumlah Wisatawan nusantara bertambah satu satuan, maka kemungkinan nilai transformasi PDRB di

Kota/Kabupaten di Pulau Jawa akan bertambah sebanyak 8,525 x 10-8 satuan. Ini sesuai dengan temuan Setiawan *et al*. (2022) yang menyatakan jumlah wisatawan berpengaruh positif terhadap pertumbuhan ekonomi.

Peubah Luas Lahan Padi (X5) dapat diinterpretasikan jika luas lahan padi bertambah satu hektar, maka kemungkinan nilai transformasi PDRB di Kota/Kabupaten di Pulau Jawa akan bertambah sebanyak 2,12 x 10-6 satuan. Ini sesuai dengan temuan Sari dan Juliansyah (2024) yang menyatakan luas lahan pertanian berpengaruh terhadap pertumbuhan ekonomi.

Peubah Jumlah Pengangguran (X7) menunjukkan Jumlah angkatan kerja yang tidak bekerja atau sedang mencari pekerjaan. Interpretasi dari hasil ini adalah jika jumlah pengangguran bertambah satu orang, maka kemungkinan nilai transformasi PDRBdi Kota/Kabupaten di Pulau Jawa akan bertambah sebanyak 8,35 x 10-6 satuan. Ini bertentangan dengan temuan Azzahra *et al*. (2024) yang menyatakan jumlah pengangguran menekan pertumbuhan ekonomi.

Peubah Jumlah Angkatan Kerja (X8) menunjukkan Angkatan kerja adalah penduduk usia kerja (15 tahun dan lebih) yang bekerja, atau punya pekerjaan namun sementara tidak bekerja dan pengangguran. Interpretasi dari hasil ini adalah jika jumlah angkatan kerja bertambah satu orang, maka kemungkinan nilai transformasi PDRB di Kota/Kabupaten di Pulau Jawa akan bertambah sebanyak 5,29 x 10-7 satuan. Ini sesuai dengan temuan Ghassan *et al*. (2018) yang menyatakan jumlah angkatan kerja berpengaruh positif terhadap pertumbuhan ekonomi.

4. Simpulan dan Saran

Penelitian ini menunjukkan bahwa model regresi yang telah ditransformasi menggunakan Box-Cox dan diseleksi dengan *stepwise* dapat menangani penyimpangan asumsi akibat ketidaknormalan sebaran peubah respon dan meningkatkan performa sehingga model lebih dapat diandalkan. Model ini berhasil meningkatkan adjusted R-squared dari 0,6851 menjadi 0,8073 dan *mean absolute error* (MAE) dari 57227,27 menjadi 0,7439. Ini menandakan efisiensi dan optimasi dalam menjelaskan variasi data dengan model yang lebih sederhana. Berdasarkan model, terdapat lima faktor yang secara signifikan memengaruhi PDRB dari kota/kabupaten di Pulau Jawa, yaitu Indeks Pembangunan Manusia, Jumlah Wisatawan Nusantara, Luas Lahan Padi, Jumlah Pengangguran, dan Jumlah Angkatan Kerja. Kelima faktor ini dapat menjelaskan 80,73% keragaman PDRB di kota/kabupaten di Pulau Jawa dengan koefisien positif. Artinya semakin besar kelima faktor tersebut, semakin tinggi juga PDRB di kota/kabupaten tersebut. Model yang telah dirumuskan dapat dijadikan dasar kebijakan pemerintah untuk dapat memprediksi pertumbuhan PDRB di Pulau Jawa. Salah satu fokus kebijakannya adalah dengan meningkatkan sektor lapangan pekerjaan, pertanian, pariwisata, dan pembangunan manusia dan kualitas pendidikan. Peubah yang ada dapat dipertimbangkan untuk diikutsertakan pada model penelitian selanjutnya.

Daftar Pustaka

Azzahra MR, Widodo ST, Kurniawan B. 2024. Pengaruh pandemi COVID-19 terhadap pengangguran dan pertumbuhan ekonomi di Jawa Barat. Bul Ekon Pembang. 1(3):13–22.

BPS. 2024. Produk Domestik Regional Bruto Menurut Pengeluaran. Jakarta: Badan Pusat Statistik.

Fachrizal R, Djumadi, Arifianto D. 2021. Analisis pendidikan dan pengangguran terhadap kesempatan kerja di Jambi. J Pek Sos. 17(3):99–112.

Ghassan HB, Al-Hajhoj HR, Balli F. 2018. Bi-demographic changes and current account using SVAR modeling: evidence from Saudi Arabia. *arXiv preprint arXiv:1803.11161v4.*

Huda N, Indahsari K. 2021. Pengaruh rata-rata lama sekolah, angka harapan hidup dan pengeluaran per kapita terhadap pertumbuhan ekonomi di Jawa Timur. Bul Ekon Pembang. 2(1):55–66.

Judijanto J, Azizs Z. 2024. Peran konsumsi rumah tangga terhadap pertumbuhan ekonomi di Pulau Jawa. J Kebijakan Ekon Daerah. 6(2):101–110.

Nababan F, Purba M. 2023. Efisiensi industri dan dampaknya terhadap penyerapan tenaga kerja di Indonesia. J Ekon Pembang Indonesia. 18(1):67–75.

Nurfarizki A, Prabowo M, Saputri Y. 2024. Analisis pengaruh IPM dan pendidikan terhadap tingkat kemiskinan dan pertumbuhan ekonomi di Jawa Tengah. J Pembang Daerah. 9(2):112–123.

Pamungkas A, Hukom A. 2024. Analisis pengaruh IPM dan pertumbuhan ekonomi terhadap tingkat kemiskinan di Indonesia. J Ekon Aplikasi. 15(1):87–95.

Putra M, Pratama S. 2022. Faktor yang memengaruhi pertumbuhan ekonomi di Pulau Jawa. J Ekon Indones. 32(1):10–25.

Ridho P. 2021. Indeks pembangunan manusia dan pertumbuhan ekonomi: pendekatan regional. J Studi Pembangunan. 27(2):45–53.

Sari N, Juliansyah H. 2024. Pengaruh luas lahan dan tenaga kerja pertanian terhadap PDB sektor pertanian di Indonesia. J Ekon Pertanian Unimal. 7(2):73–85.

Setiawan D, Suwandi A, Mardiansyah A. 2022. Peran sektor pariwisata terhadap PDRB di daerah tujuan wisata utama. J Pariwisata dan Pembangunan Ekonomi. 10(1):56–64.

Sopan M, Budiasa IW, Dewi RK. 2022. Analisis faktor yang memengaruhi laju pertumbuhan sektor pertanian pada PDRB Kabupaten Klungkung. J Agribis dan Agrowisata. 11(2):789–792.

Sopiah R, Suryadi M. 2020. Pengaruh tingkat pengangguran terhadap pertumbuhan ekonomi: studi kasus Jawa Barat. J Ekon dan Kebijakan Publik. 4(2):133–145.

Trisnawati A, Prasetyanto H. 2022. Dampak tingkat kemiskinan terhadap pertumbuhan ekonomi di Indonesia: pendekatan jangka panjang dan pendek. J Ekon Pembang Berkelanjutan. 11(1):32–44.

Violin S, Lutfi R. 2022. Ketimpangan pertumbuhan ekonomi antarprovinsi di Pulau Jawa. J Ekon Wilayah. 8(1):88–99.

Wijayanti D, Mufarrah R. 2024. Analisis dampak PDRB, investasi, rata-rata lama sekolah dan upah minimum terhadap kesempatan kerja di Jawa Tengah 2018–2022. J Apl Bisnis. 21(1):553–567.