DSC

Data Science Competition

ID Tim: DSC26013



@gammafest_ipb
gammafest23@gmail.com
#gammafest2026

Penanganan *Feature Gap* pada Prediksi Skor Sepak Bola Menggunakan Rekonstruksi Elo Kronologis dan Model *Hybrid* LightGBM-Poisson

PENDAHULUAN

Sepak bola adalah olahraga paling populer di dunia dengan 3.5 miliar penggemar global (FIFA, 2022). Sejak Maher (1982) membuktikan bahwa gol sepak bola mengikuti distribusi Poisson, model prediksi skor terus berkembang. Studi terbaru seperti Rodrigues dan Pinto (2022) serta Hassard dan Kerr (2024) telah mengeksplorasi pendekatan *machine learning* untuk memprediksi skor. Namun, kedua studi tersebut menggunakan fitur latih dan uji yang relatif seragam, sehingga belum menjawab kesenjangan fitur yang substansial.

Kesenjangan fitur ini disimulasikan secara ekstrem dalam kompetisi Gammafest 2026, yakni memprediksi jumlah gol dari pertandingan internasional lintas era dengan perbedaan fitur yang masif antara data latih dan data uji. Ketiadaan fitur-fitur tersebut mengharuskan rekonstruksi representasi kondisi tim secara mandiri agar prediksi tetap valid secara kausal. Tantangan ini menjadi semakin kompleks karena evaluasi menggunakan metrik nonlinier *Augmented Weighted Mean Absolute Error* (AW-MAE) yang menerapkan penalti asimetris terhadap kesalahan *outcome*. Oleh karena itu, perpaduan pergeseran distribusi multiera, hilangnya fitur performa, dan kompleksitas AW-MAE menuntut integrasi kohesif antara pemodelan statistik dan *machine learning*.

Eksperimen ini bertujuan membangun pipeline prediksi skor yang optimal terhadap AW-MAE melalui tiga sasaran: (1) mengembangkan model regresi probabilistik berbasis *gradient boosting* berobjektif Poisson untuk mengestimasi ekspektasi gol; (2) merancang strategi rekonstruksi rating Elo secara kronologis dan *state propagation* guna menjembatani kesenjangan fitur antara data latih dan data uji; serta (3) mengimplementasikan *post-processing* berbasis optimasi Bayesian untuk meminimalkan *expected loss* pada metrik evaluasi kompetisi.

LANDASAN TEORI

Dasar teoretis penelitian ini bertumpu pada model Poisson independen (Maher, 1982), yang menyatakan bahwa jumlah gol masing-masing tim berdistribusi Poisson dengan parameter intensitas λ. Karakteristik utama distribusi ini

mensyaratkan sifat equidistribution, di mana nilai rata-rata sebanding dengan variansnya. Kerangka ini kemudian disempurnakan oleh Dixon dan Coles (1997) melalui penerapan koreksi korelasi untuk skor rendah dan bobot peluruhan waktu (time-decay weighting).

Representasi kekuatan tim di atas fondasi distribusi tersebut dibangun melalui rating Elo (Elo, 1978) yang direkonstruksi secara kronologis dengan K-factor adaptif untuk mengatasi kendala data hilang masif pada variabel peringkat resmi. Pendekatan ini merujuk pada temuan Lasek et al. (2013) bahwa pembaruan Elo secara berurutan memiliki daya prediksi yang lebih kuat daripada peringkat resmi FIFA. Kesenjangan fitur dan perbedaan dimensi variabel antar-era ini secara teoretis dipandang sebagai masalah transfer learning dengan ruang sampel berbeda yang dapat menurunkan kemampuan generalisasi model (Kouw & Loog, 2021). Oleh karena itu, mekanisme ekstraksi dan state propagation diterapkan untuk mempertahankan informasi performa historis dari domain sumber ke domain target. Fitur performa terkini diterapkan menggunakan rolling window 5 dan 10 pertandingan terakhir berdasarkan rekomendasi Hubáček et al. (2019) yang seluruhnya dihitung menggunakan fungsi *shift(1)* guna mencegah kebocoran data. Selain itu, faktor kontekstual dimasukkan sebagai fitur eksogen guna mempertajam estimasi λ, meliputi keuntungan tuan rumah (Courneya & Carron, 1992; Pollard & Gómez, 2014) serta produk domestik bruto (PDB) per kapita dan populasi dalam skala logaritmik (Hoffmann et al., 2002).

LightGBM (Ke et al., 2017) dipilih sebagai *base learner* karena menyediakan objektif Poisson yang mengoptimalkan *negative log-likelihood* distribusi gol secara langsung. Inovasi *Gradient-based One-Side Sampling* (GOSS) dan *Exclusive Feature Bundling* (EFB) di dalamnya menjamin efisiensi pelatihan pada data tabular heterogen. Pemilihan model berbasis pohon ini didukung oleh Grinsztajn et al. (2022) yang membuktikan keunggulannya atas *deep learning* untuk dataset skala menengah. Selanjutnya, parameter kalibrasi akhir dioptimalkan menggunakan Optuna (Akiba et al., 2019) dengan algoritma *Tree-structured Parzen Estimator* (TPE) yang lebih efisien daripada metode *grid search* maupun *random search*.

Metrik evaluasi resmi kompetisi, yaitu AW-MAE, digunakan untuk mengukur akurasi seluruh pemodelan ini. Struktur nonlinier metrik tersebut, yang penjelasannya disajikan lebih rinci pada Lampiran D, menetapkan hierarki prioritas: ketepatan *outcome*, minimisasi *Mean Absolute* Error (MAE), dan ketepatan selisih gol. Karakteristik metrik inilah yang secara langsung mengarahkan desain arsitektur dan proses optimasi model.

PROSES ANALISIS

Analisis data dilakukan menggunakan bahasa pemrograman Python melalui alur kerja sistematis yang dipetakan pada Lampiran A. Rangkaian prosedur operasional dari setiap tahapan tersebut dijabarkan secara rinci sebagai berikut.

1. Pemisahan data mentah kompetisi secara kronologis menghasilkan data latih periode 1872–2011 sebanyak 78.772 observasi (47 variabel) yang memuat fitur Elo, peringkat, dan statistik historis, serta data uji periode 2011–2026 sebanyak 42.422 observasi (20 variabel) yang tidak memiliki fitur-fitur historis tersebut, diikuti dengan pembersihan awal pada masing-masing subset data.
2. Karakteristik data latih dianalisis untuk mengonfirmasi kesesuaian distribusi Poisson dan menghitung parameter keuntungan tuan rumah. Berdasarkan analisis ini, kondisi performa terakhir setiap tim per Agustus 2011 diekstrak dari data latih.
3. Kesenjangan fitur diatasi dengan memetakan kondisi (*state propagating*) terakhir tim dari data latih ke dalam data uji. Tim baru yang tidak memiliki rekam jejak pada data latih diberikan nilai dasar standar (Elo = 1500, `days_since_last_match` = 9999, ‘elo_missing_team’ = 1).
4. Peringkat FIFA yang memiliki banyak data hilang diganti sepenuhnya dengan rating Elo hasil rekonstruksi kronologis sejak tahun 1872 menggunakan faktor K adaptif. Tahap ini menghasilkan 56 fitur numerik (kontekstual, era, sosio-ekonomi, dan interaksi) yang seluruhnya dihitung menggunakan fungsi *shift(1)* demi menghindari kebocoran data.
5. Dataset pemodelan akhir dibagi secara kronologis menjadi 90% data latih dan 10% data validasi internal. Selanjutnya, tiga arsitektur model

LightGBM (M_t, M_o, dan M_c) dilatih secara paralel untuk memprediksi jumlah gol tim, gol lawan, serta hasil akhir pertandingan (W/D/L).

6. Parameter model dioptimalkan menggunakan Optuna TPE melalui 30 uji coba. Hasil prediksi akhir kemudian ditentukan melalui metode minimisasi expected loss terhadap 53 kandidat skor diskrit guna mengoreksi kelemahan prediksi hasil seri sekaligus mengoptimalkan skor pada metrik nonlinier AW-MAE.

HASIL ANALISIS

Optimasi Bayesian menggunakan Optuna selama 30 uji coba menunjukkan pola konvergensi yang cepat dan terarah. Pada tahap awal pencarian (seperti pada uji coba 0), model menghasilkan skor internal AW-MAE sebesar 2,759. Penurunan nilai metrik terjadi secara signifikan pada sepuluh uji coba pertama sebelum akhirnya mencapai titik optimal pada uji coba ke-2 dengan skor internal AW-MAE sebesar 2,678. Visualisasi pergerakan nilai metrik sepanjang proses optimasi ini disajikan secara lengkap melalui kurva konvergensi pada Lampiran F. Pola konvergensi ini menegaskan bahwa ruang pencarian parameter yang didefinisikan sangat representatif dan batas 30 uji coba sudah memadai untuk mengidentifikasi nilai global terbaik tanpa eksploitasi komputasi yang berlebihan. Kombinasi parameter hasil optimasi terbaik disajikan pada Tabel 1.

Tabel 1: Parameter Optimal Pascapemrosesan Hasil Optimasi Optuna

Parameter	Nilai Optimal	Komponen Terkait	Interpretasi dan Justifikasi Teoretis
b_t	1,004	Model Gol Tim (M_t)	Multiplikator ekspektasi gol tim utama guna menjaga stabilitas prediksi lintas era.
b_o	0,973	Model Gol Lawan (M_o)	Deflator ekspektasi gol lawan untuk menyeimbangkan asimetri gol kandang–tandang internasional.
d_m	1,292	Probabilitas Seri	Amplifikasi probabilitas seri sebesar 29,2% guna mengoreksi underprediction hasil imbang (Dixon & Coles, 1997).
c_w	0,355	Bobot Model Klasifikasi (M_c)	Pengondisian bobot model klasifikasi diskriminatif untuk meminimalkan penalti terbesar outcome pada AW-MAE.

Analisis kontribusi variabel juga dilakukan untuk mengevaluasi dampak rekayasa fitur terhadap performa model. Berdasarkan peringkat 15 fitur terpenting untuk model gol tim (M_t) yang disajikan pada Lampiran G, rating Elo hasil rekonstruksi kronologis dan fitur rolling window performa terbukti menjadi prediktor paling dominan dalam mengestimasi intensitas gol. Secara keseluruhan, keempat parameter optimal pada Tabel 1 tidak bersifat arbitrer, melainkan merespons keterbatasan spesifik yang inheren pada model Poisson independen. Keberhasilan penurunan skor dari 2,759 (sebelum optimasi) menjadi 2,683 (setelah optimasi) membuktikan bahwa lapisan pascapemrosesan berbasis optimasi Bayesian bertindak sebagai koreksi teoretis yang kuat terhadap asumsi independensi gol yang tidak terpenuhi sepenuhnya oleh karakteristik data empiris.

KESIMPULAN DAN REKOMENDASI

Penelitian ini berhasil membangun pipeline prediksi skor pertandingan sepak bola internasional yang dirancang secara spesifik untuk struktur AW-MAE. Pendekatan hibrida yang mengintegrasikan tiga model LightGBM dengan lapisan pascapemrosesan berbasis optimasi Bayesian terbukti efektif mengatasi dua tantangan utama kompetisi. Pertama, kesenjangan fitur antar-era berhasil dijembatani melalui rekonstruksi rating Elo secara kronologis dan *state propagation*. Kedua, karakteristik nonlinier AW-MAE direspons secara tepat melalui pemilihan skor diskrit berbasis minimisasi *expected loss*. Integrasi menyeluruh ini secara empiris berhasil meningkatkan akurasi model dengan menurunkan nilai AW-MAE internal dari 2,759 menjadi 2,683.

Rekomendasi pengembangan penelitian mencakup penambahan mekanisme time-decay weighting pada fitur rolling window agar pertandingan yang lebih baru mendapat bobot lebih besar dalam merepresentasikan kondisi tim terkini. Selain itu, pengujian koreksi Dixon-Coles secara eksplisit pada probabilitas skor rendah disarankan sebagai alternatif parameter d_m yang saat ini dikalibrasi secara empiris. Langkah ini penting dilakukan agar koreksi terhadap underprediction frekuensi hasil seri memiliki pijakan teoretis yang lebih kuat.

DAFTAR PUSTAKA

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2623–2631. https://doi.org/10.1145/3292500.3330701

Courneya, K. S., & Carron, A. V. (1992). The home advantage in sport competitions: A literature review. *Journal of Sport and Exercise Psychology*, *14*(1), 13–27. https://doi.org/10.1123/jsep.14.1.13

Dixon, M. J., & Coles, S. G. (1997). Modelling association football scores and inefficiencies in the football betting market. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, *46*(2), 265–280. https://doi.org/10.1111/1467-9876.00065

Elo, A. E. (1978). *The rating of chessplayers, past and present*. Arco Publishing.

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why tree-based models still outperform deep learning on tabular data. *Advances in Neural Information Processing Systems*, *35*, 507–520.

Hassard, P., & Kerr, D. (2024). Predicting football match outcomes using event data and machine learning algorithms. *Proceedings of the 35th Irish Systems and Signals Conference (ISSC 2024)*.

Hoffmann, R., Ging, L. C., & Ramasamy, B. (2002). The socio-economic determinants of international soccer performance. *Journal of Applied Economics*, *5*(2), 253–272. https://doi.org/10.1080/15140326.2002.12040579

Hubáček, O., Šourek, G., & Železný, F. (2019). Exploiting sports-betting market using machine learning. *International Journal of Forecasting*, *35*(2), 783–796. https://doi.org/10.1016/j.ijforecast.2019.01.001

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, *30*, 3146–3154.

Kouw, W. M., & Loog, M. (2019). An introduction to domain adaptation and transfer learning (arXiv:1812.11806). arXiv. https://doi.org/10.48550/arXiv.1812.11806

Lasek, J., Szlávik, Z., & Bhulai, S. (2013). The predictive power of ranking systems in association football. *International Journal of Applied Pattern Recognition*, *1*(1), 27–46. https://doi.org/10.1504/IJAPR.2013.052339

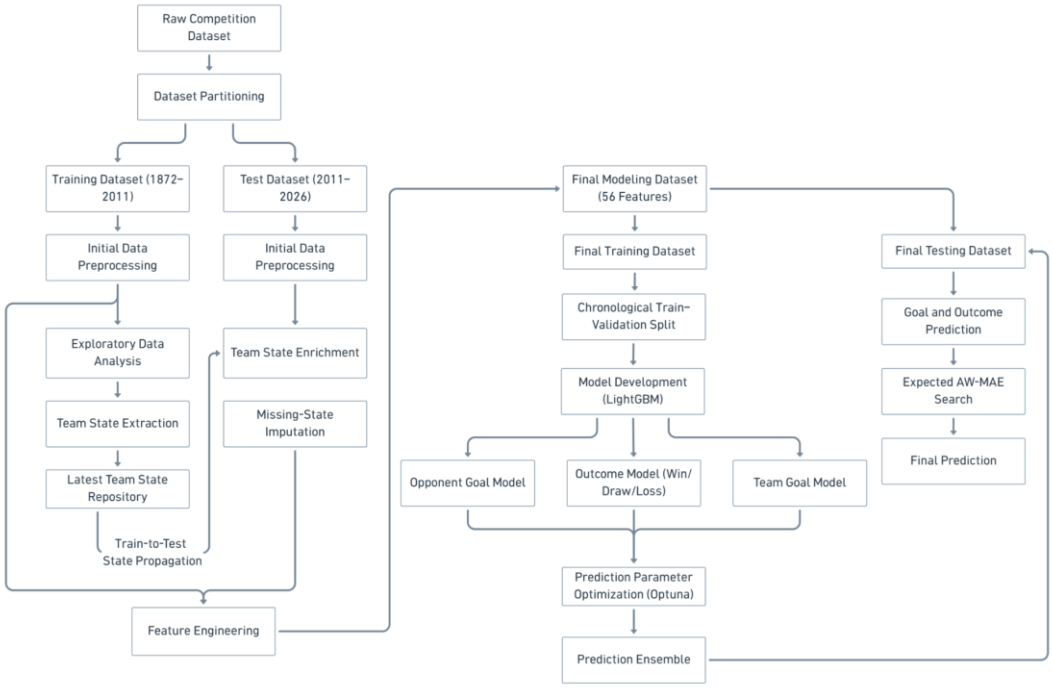
Maher, M. J. (1982). Modelling association football scores. *Statistica Neerlandica*, *36*(3), 109–118. https://doi.org/10.1111/j.1467-9574.1982.tb00782.x

Pollard, R., & Gómez, M. A. (2014). Comparison of home advantage in men's and women's football leagues in Europe. *European Journal of Sport Science*, *14*(S1), S77–S83. https://doi.org/10.1080/17461391.2011.651490

Rodrigues, F., & Pinto, Â. (2022). Prediction of football match results with machine learning. *Procedia Computer Science*, *204*, 463–470. https://doi.org/10.1016/j.procs.2022.08.057

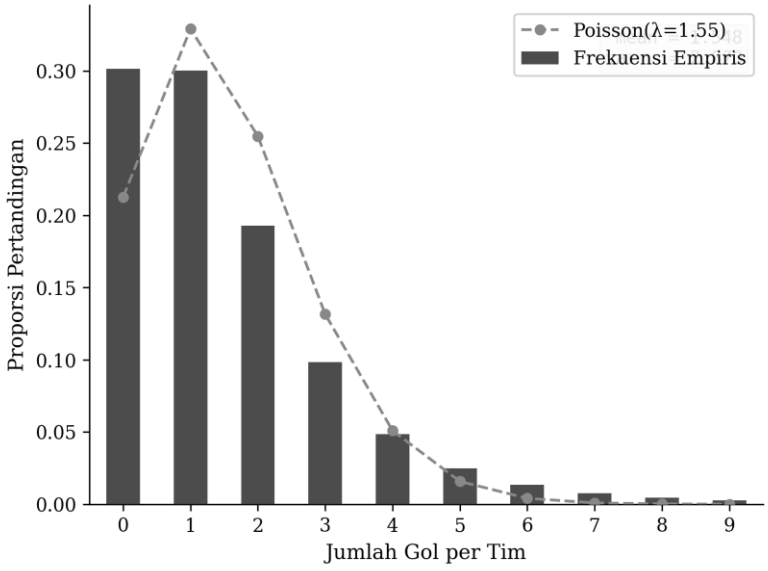
LAMPIRAN

Lampiran A: Diagram Alir Proses Analisis

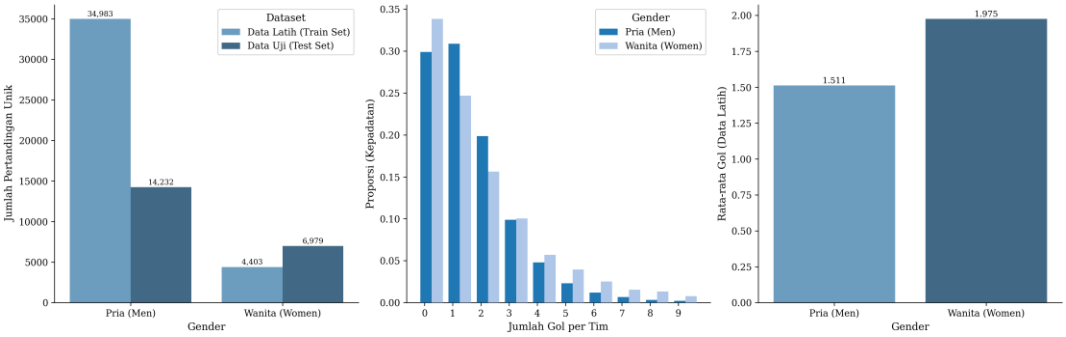


Lampiran B: Hasil Eksplorasi Data

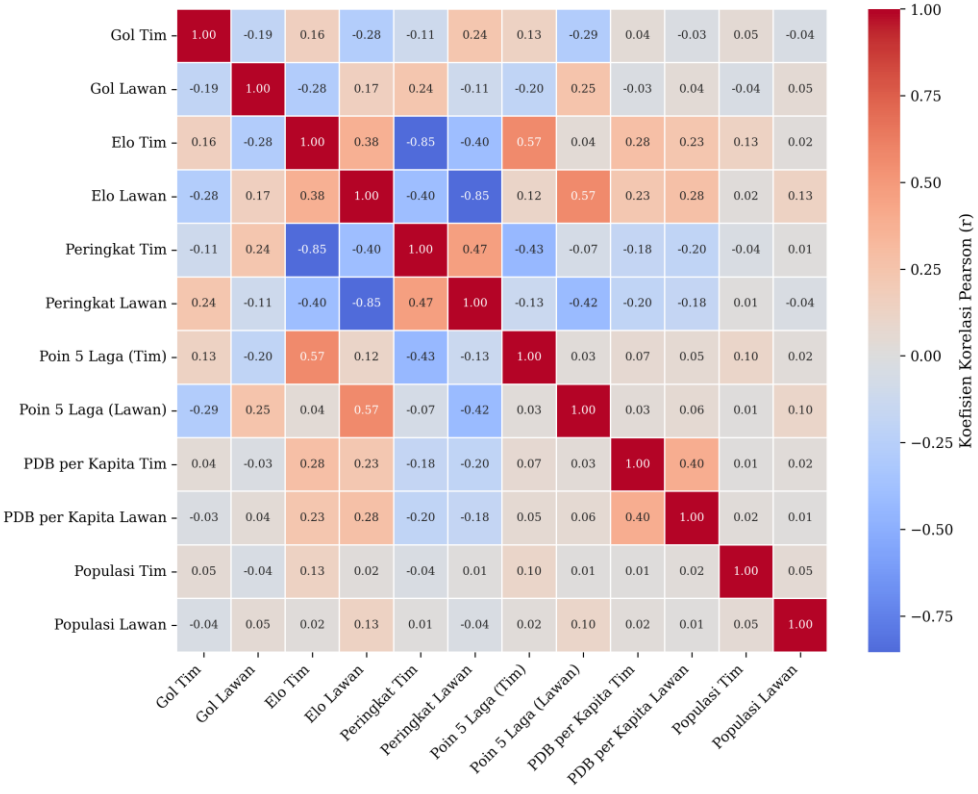
B.1 Distribusi Gol Empiris terhadap Distribusi Poisson Teoretis



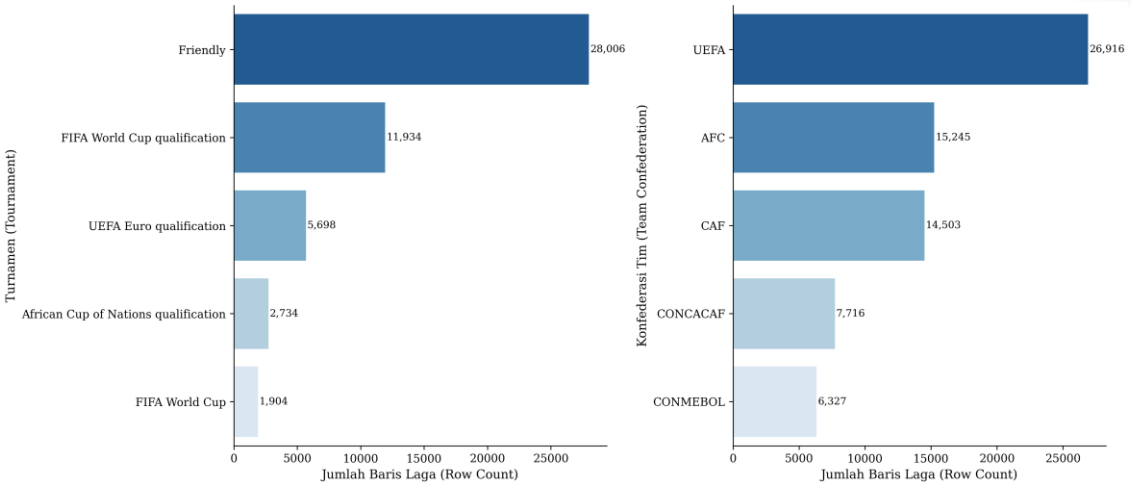
B.2 Analisis Karakteristik Demografis Pertandingan Berdasarkan Gender



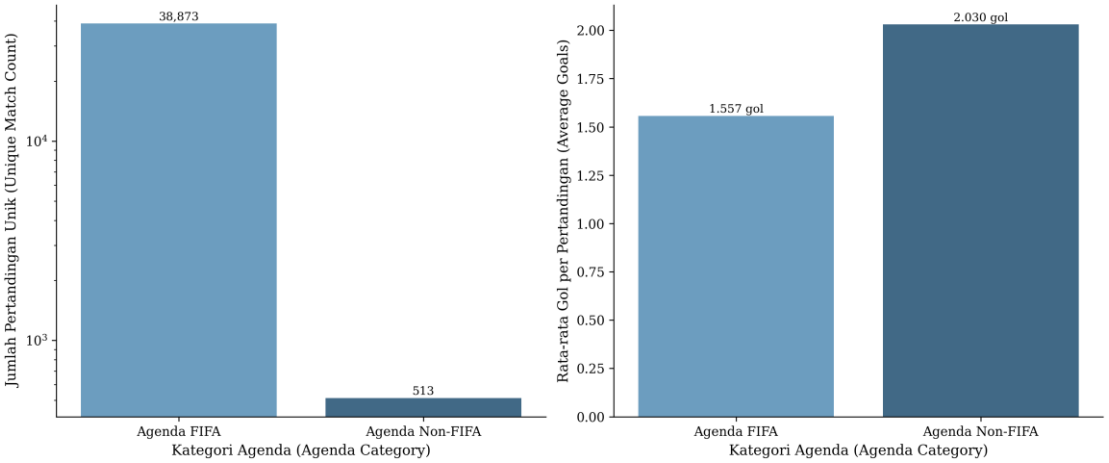
B.3 Heatmap Korelasi Pearson Antara 12 Fitur Numerik Utama



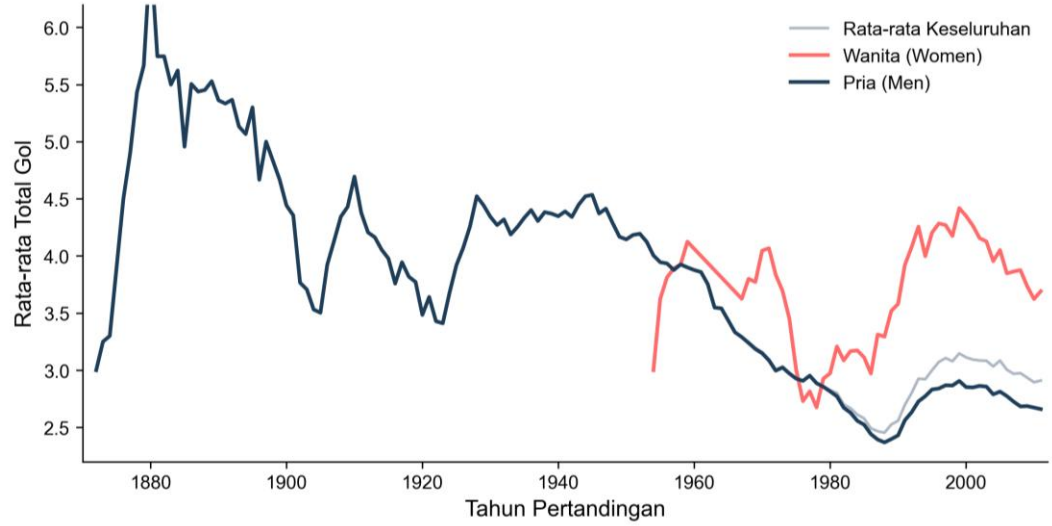
B.4 Distribusi jumlah laga pada lima Turnamen dan Konfederasi Tertinggi



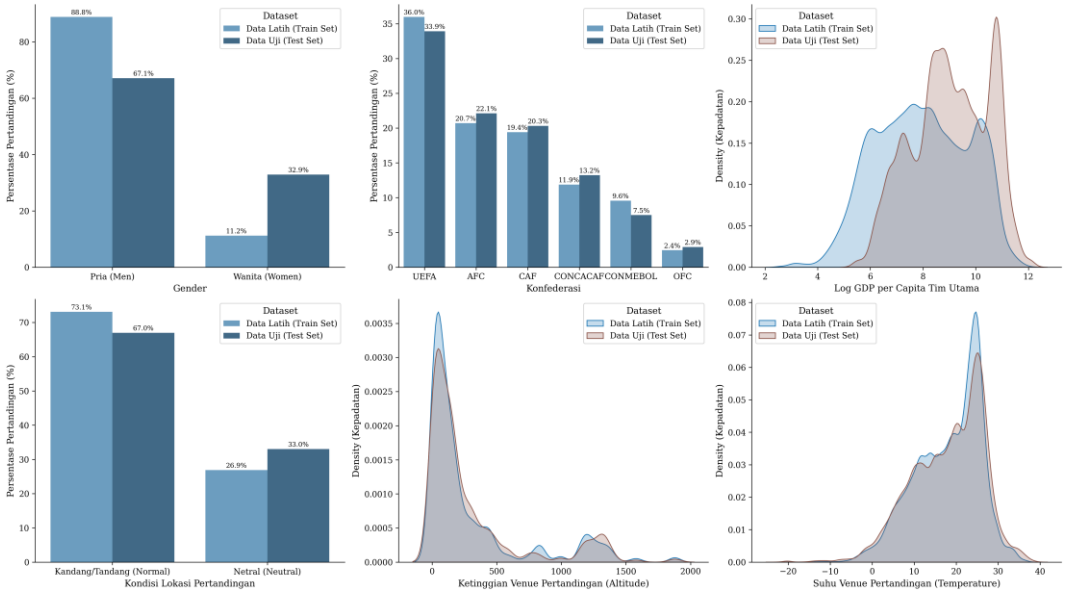
B.5 Jumlah Pertandingan Unik dan Rata-rata Gol Berdasarkan Kategori Agenda FIFA vs Non-FIFA



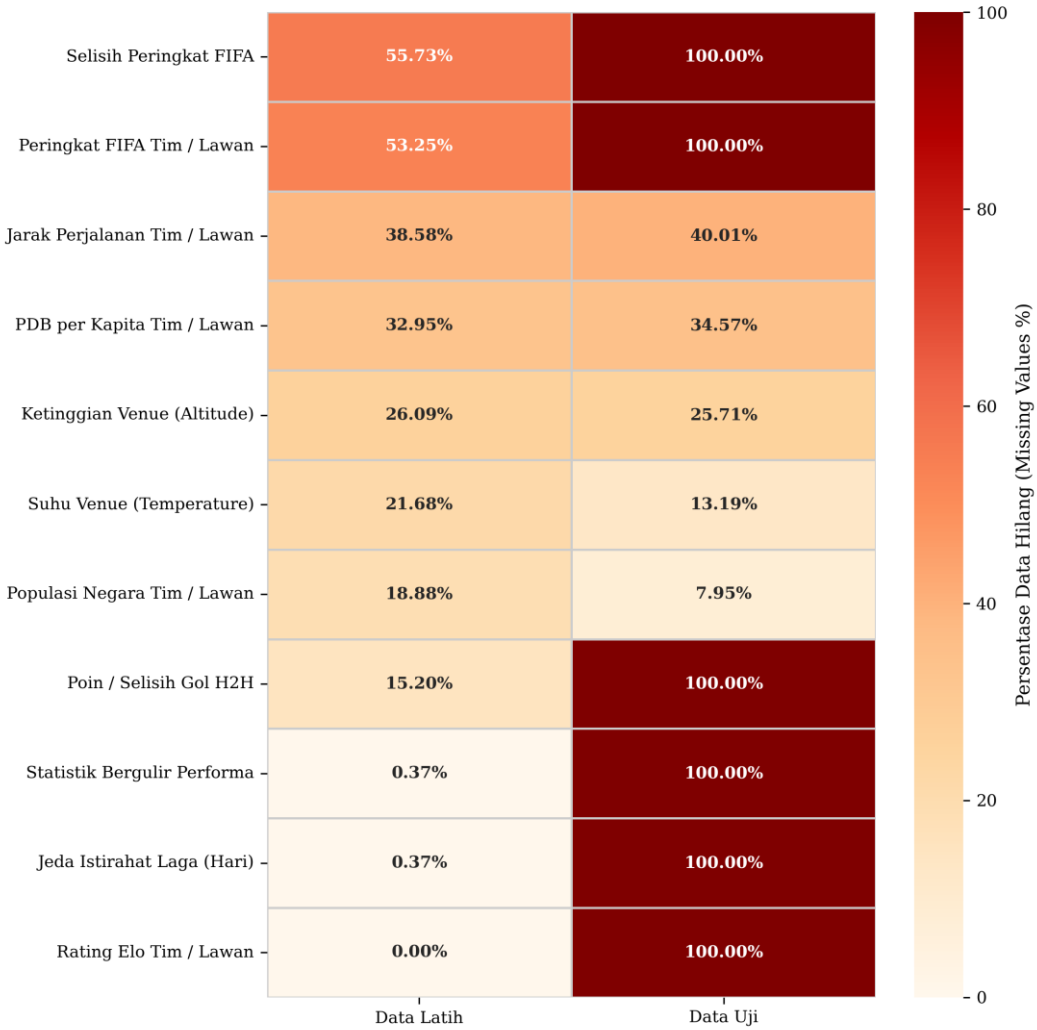
B.6 Tren Rata-rata Total Gol per Pertandingan (*Moving Average* 5 Tahun)



B.7 Pergeseran Distribusi pada Data Latih dan Data Uji



B.9 Persentase Missing Values pada Data Latih dan Data Uji



Lampiran C: Metodologi rekonstruksi ELO dan Propagasi State Tim

C.1 Formula Rekonstruksi Rating Elo Kronologis

Sistem rating Elo (Elo, 1978) diadaptasi untuk kuantifikasi kekuatan tim nasional sepak bola secara kronologis sejak pertandingan internasional pertama pada tahun 1872. Untuk setiap pertandingan ke-t, rating baru tim (R_t) diperbarui dari rating sebelumnya ($R_t - 1$) menggunakan persamaan berikut.

$$R_t = R_{t-1} + K(S - S_{hat})$$

Keterangan:

S: Hasil pertandingan aktual (1.0 untuk menang; 0.5 untuk seri; 0.0 untuk kalah).

S_{hat}: Ekspektasi hasil pertandingan yang dihitung dengan fungsi logistik:

$$S_{hat} = \frac{1}{\left(1 + 10^{-\frac{d_{Elo} + H}{400}}\right)}$$

Dengan:

- $d_{Elo} = \mathrm{R_{team}} - \mathrm{R_{opp}}$ adalah selisih rating Elo sebelum laga.
- H adalah *Home Advantage Bonus* (ditetapkan sebesar +100 poin Elo jika tim bertindak sebagai tuan rumah di stadion sendiri, dan 0 jika laga netral atau tandang).

Adaptive K-factor Berdasarkan Kategori Turnamen

Untuk mengakomodasi bobot kepentingan dan intensitas kompetitif dari berbagai kategori kompetisi, nilai K-factor diatur secara adaptif sebagai berikut:

- K = 20 untuk pertandingan persahabatan yang memiliki volatilitas hasil tinggi dan dampak kompetitif rendah.
- K = 40 untuk laga kualifikasi kontinental serta turnamen regional menengah.
- K = 60 untuk turnamen final tingkat kontinental dan turnamen tingkat global tertinggi.

C.2 Mekanisme State Propagation Latih ke Uji

Feature gap diselesaikan melalui dua langkah state propagation sistematis:

1. Ekstraksi State Terakhir (Per Agustus 2011):
   State performa terakhir setiap tim nasional diekstraksi tepat pada batas akhir periode data latih. *State* ini mencakup: Rating Elo tim dan lawan, performa poin bergulir 5 dan 10 laga terakhir, Statistik produktivitas gol Statistik historis head-to-head (H2H) antar kedua tim.
2. Pemetaan Sekuensial dan *Baseline*:
   State terakhir tersebut dipetakan sebagai titik awal pada data uji. Tim baru yang tidak memiliki catatan historis pada data latih diberikan nilai *baseline* konservatif yang mencakup: Rating Elo *baseline* (R_0) = 1.500, waktu istirahat sejak laga terakhir = 9.999 hari (sebagai penanda tidak aktif yang masif), fitur 'elo_missing_team' = 1 untuk membedakan tim yang sebenernya memiliki elo 1500 dengan tim yang menggunakan nilai *baseline*.

C.3 Daftar Lengkap Fitur

Hasil dari *feature engineering pipeline* menghasilkan total 56 fitur numerik komprehensif yang diklasifikasikan ke dalam 6 dimensi analitik berikut:

Kategori Fitur	Jumlah	Daftar Nama Fitur Utama	Deskripsi/Tujuan Analisis
Fitur Kekuatan Utama	8	• Rating Elo • Selisih rating Elo	Mengukur kekuatan absolut dan relatif tim berdasarkan sistem rating Elo.
Fitur *Rolling Performance*	16	• Akumulasi poin dan tingkat kemenangan (5 & 10 laga terakhir). • Rata-rata gol memasukkan dan gol kebobolan (5 laga terakhir). • Selisih poin dan selisih gol performa terkini. • Poin dan selisih gol pertemuan historis kedua tim (*Head-to-Head*).	Menangkap tren performa terkini, produktivitas serangan, kokohnya pertahanan, serta rekam jejak pertemuan historis (H2H).
Fitur Kontekstual dan Lingkungan	10	• Keuntungan kandang (*home advantage*) dan laga stadion netral. • Ketinggian (*altitude*) dan suhu (*temperature*) tempat bertanding. • Estimasi jarak perjalanan ke lokasi pertandingan. • Status kesamaan konfederasi regional tim.	Mengakomodasi faktor non-teknis seperti keuntungan kandang, efek stadion netral, kelelahan perjalanan (travel distance), ketinggian ekstrem, dan suhu.
Fitur Sosio-Ekonomi dan Demografis	10	• Jumlah populasi dan PDB (*GDP*) per kapita negara tim serta lawan. • Penanda khusus negara mikro (*microstate*).	Memasukkan kapasitas sumber daya negara (log gdp/populasi) untuk memprediksi investasi dan kualitas pembinaan sepak bola.
Fitur Penjadwalan dan Waktu	6	• Tanggal, bulan, dan tahun pertandingan • Jumlah hari sejak laga terakhir tim dan lawan serta selisihnya.	Mengukur kebugaran tim berdasarkan jeda istirahat (hari sejak laga terakhir) serta menangkap tren musiman/tren era.
Fitur Interaksi Rekayasa	6	• Interaksi rating Elo gabungan dengan keuntungan kandang. • Status pertandingan lintas benua (*intercontinental*). • Kategori era sejarah dekade pertandingan. • Jenis kelamin pertandingan (pria vs wanita). • Penanda khusus pertandingan non-agenda FIFA. • Bobot tingkat kepentingan turnamen.	Fitur interaksi tingkat lanjut seperti gabungan rating Elo dan home advantage, penanda agenda non-FIFA, era laga, dan bobot turnamen.

Lampiran D: Metrik Evaluasi AW-MAE

Metrik evaluasi resmi kompetisi dirancang secara khusus untuk memberikan penilaian komprehensif yang tidak hanya mengukur deviasi absolut angka gol, melainkan juga menghargai ketepatan hasil akhir (*outcome*) dan selisih gol (*goal difference*).

Formulasi matematis resmi AW-MAE didefinisikan sebagai berikut:

$$AW - MAE = \Sigma_i(Loss_i \times W_i) / \Sigma_i W_i$$

Dengan:

W_i (Bobot Turnamen): Merupakan bobot signifikansi turnamen berdasarkan tingkat kepentingan kompetisi sepak bola internasional. Contoh: Piala Dunia FIFA (W_i = 2.0), Piala Kontinental (W_i = 1.8), Laga Kualifikasi Resmi (W_i = 1.3), Turnamen Minor (W_i = 1.2), dan Pertandingan Persahabatan (W_i = 0.96).

Perhitungan nilai kerugian individual ($Loss_i$) dirumuskan sebagai:

$$Loss_i = [(MAE_i + Penalty_i) \times M_i]^{1.5}$$

Dengan:

M_i (Multiplier): Konstanta pengali skala dasar untuk menormalkan rentang kesalahan.

Eksponen nonlinear (1.5): Memberikan penalti yang lebih berat pada deviasi kesalahan prediksi berskala besar (large errors) untuk mendorong stabilitas estimasi skor.

Pengali penalti ($Penalty_i$) didefinisikan melalui persamaan:

$$Penalty_i = 0.30(1 - Exact) + 0.25(1 - Outcome) + 0.15(1 - GD)$$

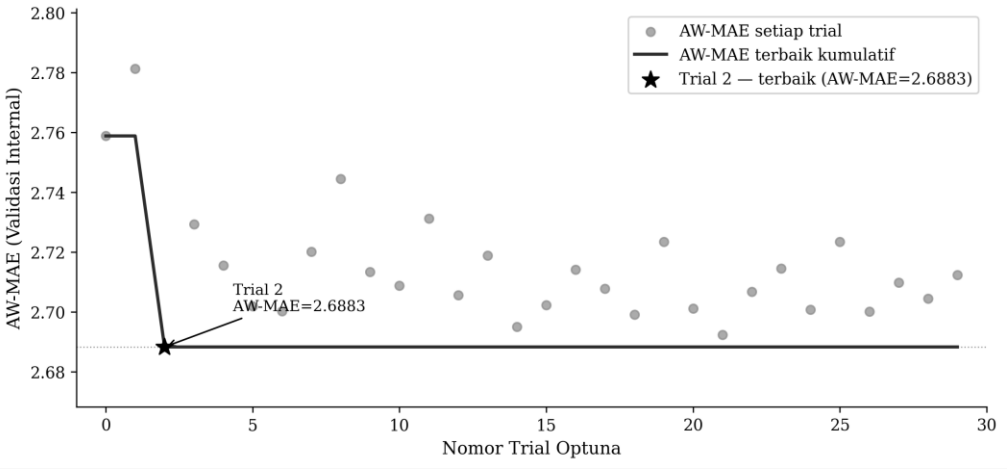
Dengan:

Exact: Bernilai 1 jika prediksi skor akhir tepat sama dengan skor aktual dan bernilai 0 jika terjadi perbedaan angka.

Outcome: Bernilai 1 jika prediksi hasil pertandingan (Menang/Seri/Kalah) sama dengan hasil aktual dan bernilai 0 jika salah memprediksi hasil akhir.

GD (Goal Difference): Bernilai 1 jika prediksi selisih gol sama dengan selisih gol aktual dan bernilai 0 jika berbeda.

Lampiran F: Kurva Konvergensi Optimasi Bayesian Parameter Model



Lampiran G: Peringkat 15 Fitur Terpenting Model m_t

