Penanganan Feature Gap pada Prediksi Skor Sepak Bola Menggunakan Rekonstruksi Elo dan LightGBM-Poisson

DSC26013 – Bumbu Ireng Pak Jenggot

starcore.co

LATAR BELAKANG

Mengapa Ini Sulit ?

Tantangan yang sulit diselesaikan dengan pendekatan konvensional.

78772
Data Latih, 1872-2011

42422
Data Uji, 2011-2026

0.25 + (x1.5)
Salah Prediksi Outcome

47 vs 20

Jumlah fitur

Feature Gap Data Train dan Test yang Masif

Data latih memiliki 47 fitur termasuk ELO dan statistik historis, sementara data uji hanya 20 fitur. **Fitur-fitur penting tidak tersedia** saat prediksi.

154

Tahun data (1872-2026)

Distribusi Data Lintas Era

Dataset mencakup lebih dari satu abad pertandingan internasional. Gaya bermain, kekuatan tim, dan kondisi pertandingan **berubah secara drastis lintas era**.

4 Dimensi

Akurasi simultan

Metrik AW-MAE yang Non-Linear

Bukan sekadar MAE umumnya. AW-MAE menggabungkan **ketepatan skor, arah hasil, selisih gol, dan bobot turnamen** dengan penalti asimetris.

LANDASAN TEORI

Distribusi Poisson Independen

Maher (1982) - Statistica Neerlandica

Gol masing-masing tim berdistribusi Poisson secara independen. Terkonfirmasi pada data kami dengan mean = 1.56 dan varians = 1.58 yang identik.

Koreksi Dixon-Coles

Applied Statistics

Koreksi korelasi skor rendah dan time-decay weighting menjadi fondasi parameter ***dm*** dalam pipeline kami.

ELO dan Form Rolling

Lasek, Hubacek

Elo yang diperbarui berurutan lebih prediktif. Fitur form 5 & 10 match terakhir adalah prediktor terkuat prediksi hasil tim.

Fondasi Ilmiah Pipeline Kami



Setiap keputusan rancangan metodologi kami berakar pada literatur yang telah terbukti dan tervalidasi.

LightGBM Model

Model berbasis pohon unggul atas deep learning pada data tabular berskala puluhan ribu sampel Grinsztajn et al. (2022).

Optune TPE

Tree-structured Parzen Estimator lebih efisien dari grid search untuk optimasi parameter kontinu. (Akiba et al., 2019)

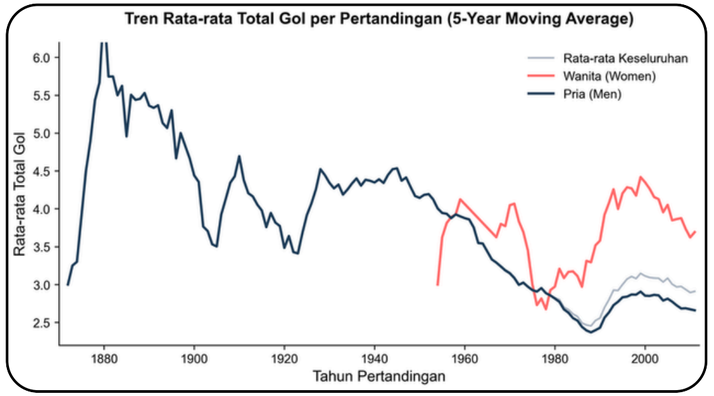
EKSPLORASI DATA

Karakteristik Data

Variabel	Jumlah	Cakupan
Sosioekonomi	4	Populasi dan GDP per-kapita
Konteks & Geografis	11	Lokasi, jarak tempuh, suhu, ketinggian, konfederasi, gender, turnamen
Metrik Kekuatan	7	ELO, Rank
Performa Historis	16	Poin, GD, H2H, Win Rate (Last 5 & 10 Matches)

Tidak ada di data *test* !

Temuan Hasil EDA

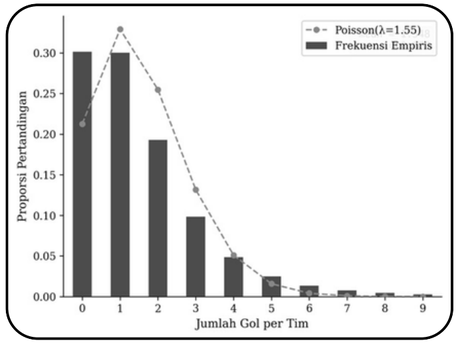


Produktivitas gol **menurun tiap era**, dengan **tren gol** laga **wanita melampaui rata-rata laga pria.**

0.651
Selisih rata-rata gol positif signifikan dari keuntungan tuan rumah

Temuan Kunci Lainnya

- **35.55%** Turnamen adalah ***Friendly***, **34.17%** ***konfederasi*** adalah UEFA
- Rata-rata gol agenda FIFA dan non-FIFA berbeda **signifikan**
- **Tim nasional baru** di data test **tidak memiliki riwayat performa**



Proporsi sebaran jumlah gol per tim pada pertandingan, terbukti mengikuti **distribusi Poisson**

PRE-PROCESSING

Alur Pre-Processing

dan Fitur setelah Feature Engineering

Data Preprocessing

Forward fill data kosong, Menghapus nilai sentinel, dan transformasi logaritma fitur sosio-ekonomi.

Ekstraksi Temporal

Dari data mentah diekstraksi menjadi detail temporal penting seperti days since last match.

Feature Engineering

Differential Features, Era Features, Missing Observation Features, Log Socio-Economic.

Sosio-ekonomi

`population_team` `population_opp`
`gdp_per_capita_team` `gdp_per_capita_opp`
`population_team_log` `population_opp_log`
`gdp_per_capita_team_log` `gdp_per_capita_opp_log`
`is_microstate_team` `is_microstate_opp`

Konteks & Geografis

`is_home` `neutral` `is_home_country` `is_none_fifa`
`is_opponent_home_country` `same_confederation`
`is_intercontinental` `altitude_venue` `temperature_venue`
`distance_travel_team` `distance_travel_opp`
`is_male` `days_since_last_match_team`
`days_since_last_match_opp` `tournament_weight`
`days_since_last_match_diff`

Metrik Kekuatan

`elo_team` `elo_opponent` `elo_diff` `elo_home_adv`
`elo_team_missing` `elo_opp_missing` `era` `year` `month`
`rank_missing_team` `rank_missing_opp` `day_of_week`

Performa Historis

`team_points_last5` `opp_points_last5` `team_gd_last5`
`opp_gd_last5` `team_points_last10` `opp_points_last10`
`team_avg_conceded_last5` `opp_avg_conceded_last5`
`team_win_rate_last10` `opp_win_rate_last10`
`points_last5_diff` `gd_last5_diff` dan 6 fitur lainnya...

Pre-Processing Data
dan Feature Engineering

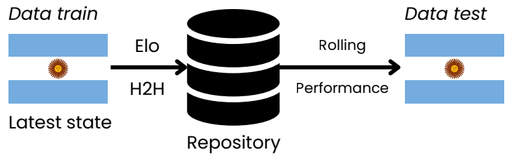
Rekonstruksi ELO Kronologis

$$R_t = R_{t-1} + \mathbf{K}(S - \hat{S}) + \text{Home_Adv}$$

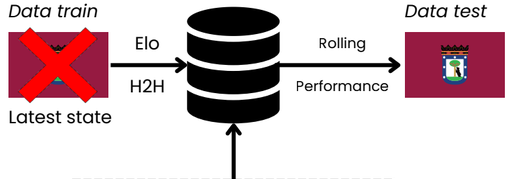
+150

**Adaptif* berdasarkan kualitas pertandingan

State Propagation



Missing State Imputation



- **Baseline Elo** = 1500
- **Days since last match** = 9999
- **ELO missing team** = 1

Keterangan Adaptif berdasarkan kualitas pertandingan:

- K-factor=20, untuk laga friendly
- K=40, untuk laga kualifikasi
- K=60, untuk piala utama

PIPELINE ANALISIS

Tools & Library

Tools & Dataset:

kaggle python

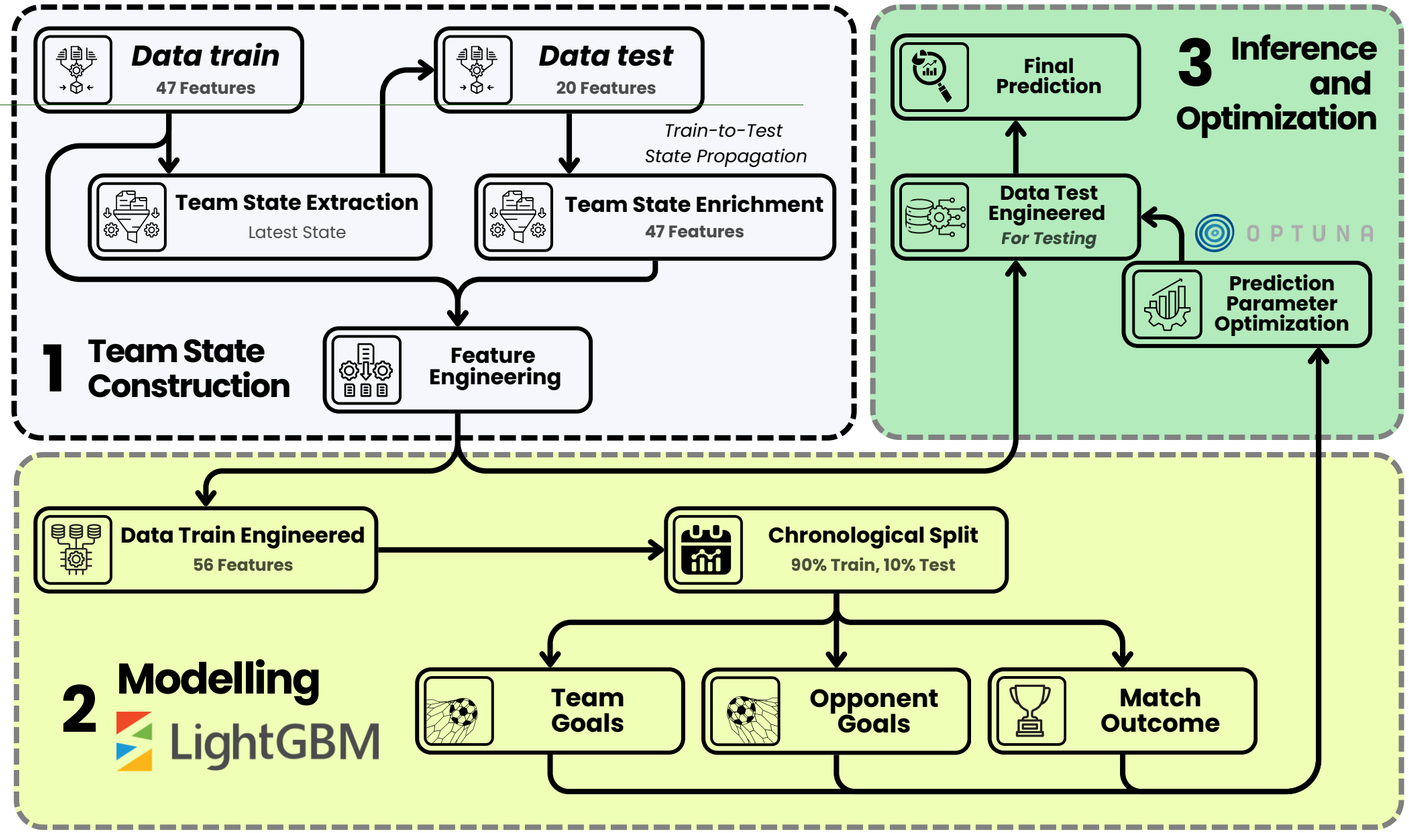
Dataset Manipulation and Visualization:

NumPy pandas matplotlib

Model Training and Optimize

scikit-learn LightGBM OPTUNA

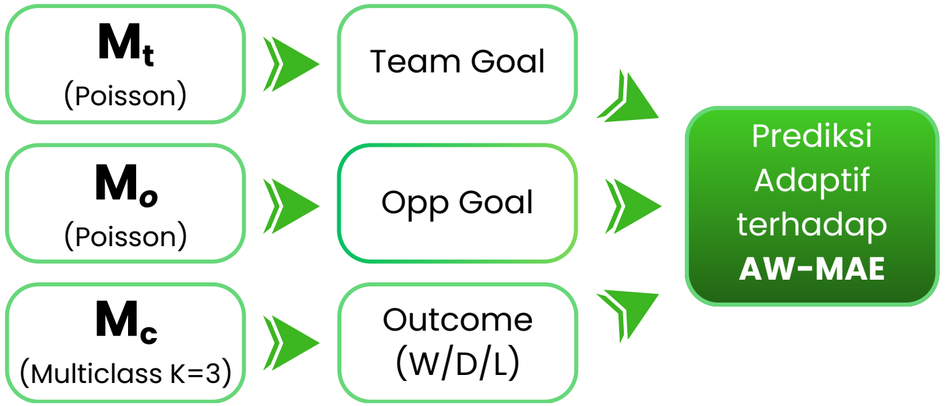
Pipeline End-to-End



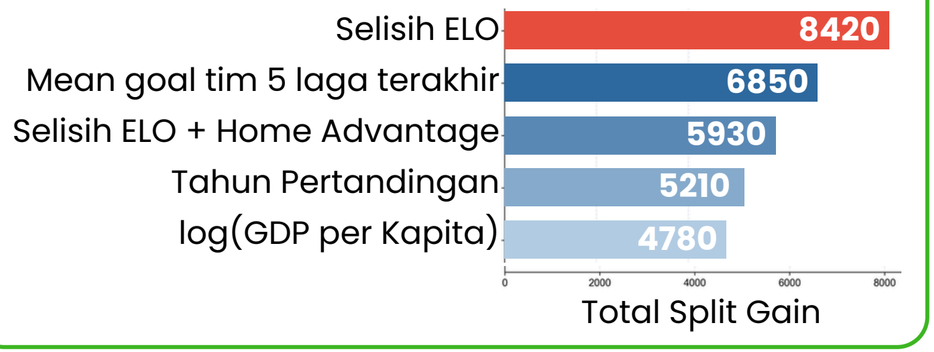
HASIL PEMODELAN

Hasil Pemodelan LightGBM

Split train kronologis 90% train / 10% validasi



5 Fitur M_t Paling Berpengaruh



Optimasi Hyperparameter dengan Optuna

Melakukan 30x Trial dan Konvergen di Trial ke-2

Parameter	Rentang Pencarian	Fungsi	Nilai Optimal
b_t	0.9 — 1.2	Faktor skala λ_t	1.004
b_o	0.9 — 1.2	Faktor skala λ_t	0.973
d_m	0.7 — 1.3	Draw multiplier	1.292
c_w	0.2 — 0.8	Bobot klasifikasi vs Poisson	0.355

Sebelum Optimasi

Public Score
2.69

Setelah Optimasi

Public Score
1.98

Kesimpulan

Feature Gap
Berhasil Diperbaiki

Dengan rekonstruksi elo kronologis + state propagation

AW-MAE Non Linear
Dioptimalkan

Pemilihan skor diskrit berbasis *expected loss minimum* dengan kalibrasi Bayesian

Hybrid Generatif-Dliskriminatif
yang lebih Robust

Dibanding mengandalkan satu pendekatan

Rekomendasi Lanjutan

- ***Time-decay weighting*** pada *rolling window* agar pertandingan terbaru dapat **bobot lebih besar**
- Gunakan **Koreksi Dixon-Coles** secara eksplisit pada probabilitas skor rendah sebagai pijakan teoritis lebih kuat untuk parameter d_m

Referensi

- Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2623–2631. https://doi.org/10.1145/3292500.3330701
- Courneya, K. S., & Carron, A. V. (1992). The home advantage in sport competitions: A literature review. Journal of Sport and Exercise Psychology, 14(1), 13–27. https://doi.org/10.1123/jsep.14.1.13
- Dixon, M. J., & Coles, S. G. (1997). Modelling association football scores and inefficiencies in the football betting market. Journal of the Royal Statistical Society: Series C (Applied Statistics), 46(2), 265–280. https://doi.org/10.1111/1467-9876.00065
- Elo, A. E. (1978). The rating of chessplayers, past and present. Arco Publishing.
- Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why tree-based models still outperform deep learning on tabular data. Advances in Neural Information Processing Systems, 35, 507–520.
- Hassard, P., & Kerr, D. (2024). Predicting football match outcomes using event data and machine learning algorithms. Proceedings of the 35th Irish Systems and Signals Conference (ISSC 2024).
- Hoffmann, R., Ging, L. C., & Ramasamy, B. (2002). The socio-economic determinants of international soccer performance. Journal of Applied Economics, 5(2), 253–272. https://doi.org/10.1080/15140326.2002.12040579
- Hubáček, O., Šourek, G., & Železný, F. (2019). Exploiting sports-betting market using machine learning. International Journal of Forecasting, 35(2), 783–796. https://doi.org/10.1016/j.ijforecast.2019.01.001

Referensi

- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems, 30, 3146–3154.
- Kouw, W. M., & Loog, M. (2019). An introduction to domain adaptation and transfer learning (arXiv:1812.11806). arXiv. https://doi.org/10.48550/arXiv.1812.11806
- Lasek, J., Szlávik, Z., & Bhulai, S. (2013). The predictive power of ranking systems in association football. International Journal of Applied Pattern Recognition, 1(1), 27–46. https://doi.org/10.1504/IJAPR.2013.052339
- Maher, M. J. (1982). Modelling association football scores. Statistica Neerlandica, 36(3), 109–118. https://doi.org/10.1111/j.1467-9574.1982.tb00782.x
- Pollard, R., & Gómez, M. A. (2014). Comparison of home advantage in men's and women's football leagues in Europe. European Journal of Sport Science, 14(S1), S77–S83. https://doi.org/10.1080/17461391.2011.651490
- Rodrigues, F., & Pinto, Â. (2022). Prediction of football match results with machine learning. Procedia Computer Science, 204, 463–470. https://doi.org/10.1016/j.procs.2022.08.057

DSC26013 – Bumbu Ireng Pak Jenggot



Alden Nabil Wibowo Effendy

Bryant Indervil Deadora

Raihan Putra Kirana

IPB University
Bogor Indonesia

IHMSI

GAMMA SIGMA BETA
INSTITUT PERTANIAN BOGOR

GAMMAFEST 2026

starcore.co



TERIMA KASIH



IPB University
Bogor Indonesia

IHMSI

GAMMA SIGMA BETA
INSTITUT PERTANIAN BOGOR

GAMMAFEST 2026

starcore.co



LAMPIRAN



AW-MAE EVALUATION

Metrik evaluasi resmi kompetisi dirancang secara khusus untuk memberikan penilaian komprehensif yang tidak hanya mengukur deviasi absolut angka gol, melainkan juga menghargai ketepatan hasil akhir (outcome) dan selisih gol (goal difference).

$$AW - MAE = \Sigma(Loss \times W)/\Sigma W$$

$$Loss = [(MAE + Penalty) \times M]^{1.5}$$

$$Penalty = 0.30(1 - Exact) + 0.25(1 - Outcome) + 0.15(1 - GD$$

W_i: Bobot Turnamen, contoh:

- Piala Dunia FIFA (W_i = 2.0)
- Piala Kontinental (W_i = 1.6)
- Laga Kualifikasi Resmi (W_i = 1.3)
- Turnamen Minor (W_i = 1.2)
- Pertandingan Persahabatan (W_i = 0.8)

M_i: Konstanta pengali skala dasar, memberikan penalti yang lebih berat pada deviasi kesalahan prediksi berskala besar

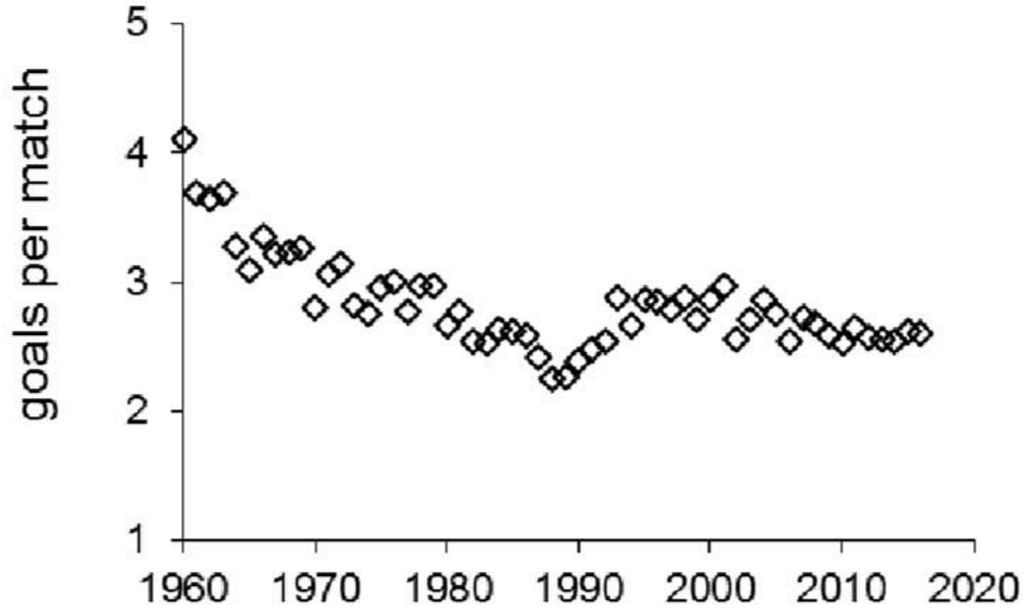
Metrik Evaluasi memberi penalti secara eksponensial dengan prioritas tebakan:

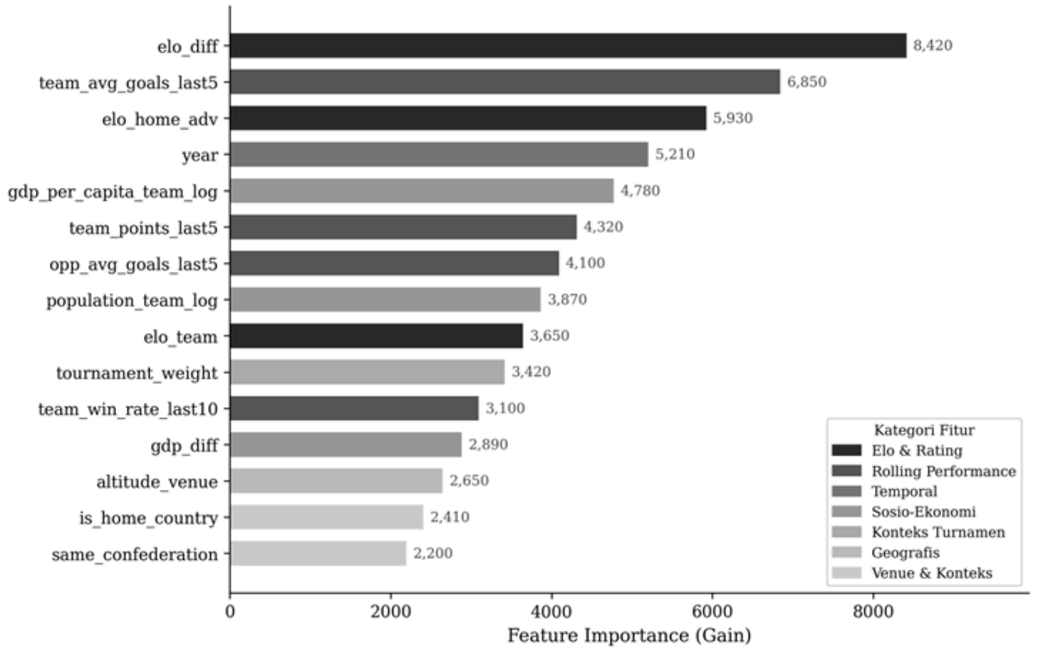
1. Ketepatan tebakan
2. Hasil akhir (W/D/L)
3. Goal Difference

Dibutuhkan model yang:

1. Mengatasi underpredict yang berisiko terkena penalti outcome
2. Ketidaksesuaian pembulatan skor dengan *Vectorized Score Search*
3. Mengatasi penalti asimetris dengan memberikan bobot dominasi klasifikasi yg tinggi agar outcome akurat
4. Mengatasi pembengkakan Eksponensial Loss dengan kalibrasi Ekspektasi gol tim kandang dan tandang

MENGAPA YAKIN DENGAN PREDIKSI





https://www.researchgate.net/figure/Mean-total-number-of-goals-per-match-by-year-in-international-soccer-for-all-matches_fig1_354351724

https://www.researchgate.net/publication/354351724_On_skill_and_chance_in_sport